

См. обсуждения, статистику и профили авторов для этой публикации по адресу: <https://www.researchgate.net/publication/340126735>.

Адаптивные стратегии машинного обучения для сетевой калибровки интеллектуальных устройств мониторинга качества воздуха IoT

Препринт · Март 2020 г.

DOI: 10.13140/RG.2.2.26209.45927

ЦИТАТЫ

0

6 авторов, в том числе:



[Саверио Де Вито](#)

ВДНХ

137 ПУБЛИКАЦИИ 1603 ЦИТАТЫ

[СМОТРЕТЬ ПРОФИЛЬ](#)



[Серхио Ферлито](#)

ВДНХ

20 ПУБЛИКАЦИИ 253 ЦИТАТА

[СМОТРЕТЬ ПРОФИЛЬ](#)

ЧИТАЕТ

181



[Елена Эспозито](#)

ВДНХ, Портичи, Италия

48 ПУБЛИКАЦИИ 687 ЦИТАТОВ

[СМОТРЕТЬ ПРОФИЛЬ](#)



[Фабрицио Формисано](#)

ВДНХ, Исследовательский центр Портичи (Северная Америка), Италия

54 ПУБЛИКАЦИИ 358 ЦИТАТОВ

[СМОТРЕТЬ ПРОФИЛЬ](#)

Некоторые авторы этой публикации также работают над следующими родственными проектами:



[МОНИКА](#) Посмотреть проект



[Ортофрулог](#) Посмотреть проект

Адаптивные стратегии машинного обучения для сети калибровка интеллектуальных устройств мониторинга качества воздуха IoT

Саверио Де Вито[□], Джироламо Ди Франсиа[□], Елена Эспозито[□], Серхио Ферлито[□], Фабрицио Формисано[□] и Этторе Массера[□]

aENEA – DTE-FSN-SAFS, P.le E. Fermi, 1, 80055 Portici (NA), Италия

Абстрактный

Мультисенсорные системы качества воздуха (AQMS) — это устройства Интернета вещей, основанные на массиве недорогих химических микродатчиков, которые недавно продемонстрировали способность давать относительно точные количественные оценки загрязнителей воздуха. Их доступность позволяет развертывать всеобъемлющие сети мониторинга качества воздуха (AQM), которые решают проблему географической разреженности, которые влияют на текущую сеть Систем Регулятивного Мониторинга AQ (AQRMS). К сожалению, их точность показан ограниченный в долгосрочном полевом развертывании из-за негативного влияния нескольких технологических проблем, включая отравление или старение датчиков, помехи от нецелевого газа, отсутствие воспроизводимости изготовления и т. д. Сезонные изменения в вероятностное распределение априорных значений, наблюдаемых и скрытых переменных контекста (т. е. ненаблюдаемых помех) бросать вызов моделям калибровки, основанным на полевых данных, которые недавно привлекли внимание к краткосрочным и среднесрочным характеристикам городских властей и контролирующим органов. В этой работе мы обращаемся к этой нестационарной структуре с адаптивным стратегии обучения, чтобы продлить срок действия моделей калибровки мультисенсоров, обеспечивающих непрерывное обучение. Анализируется влияние релевантных параметров в различных сценариях перекалибровки сети и узла к узлу. Результаты следовательно, полезно для повсеместного развертывания, нацеленного на постоянное картографирование AQ с высоким разрешением в городских сценариях, а также что касается использования AQMS в качестве резервных систем AQRMS, предоставляющих данные, когда данные AQRMS недоступны из-за сбоев или плановое техническое обслуживание.

[□] Автор, ответственный за переписку: Саверио Де Вито, доктор философии. Тел.: +39-081-772-3264; электронная почта: saverio.devito@enea.it

1. Введение

Недорогие химические мультисенсорные устройства находятся на пороге революционного изменения качества воздуха (AQ) сетей мониторинга, обеспечивающих возможность оценки индивидуального воздействия, в то время как в значительной степени улучшая распространенность существующей сети анализаторов нормативного уровня. Пока сеть регулирующего мониторинга будет по-прежнему представлять собой основу для обеспечения высочайшего качества данных AQ, несколько городов в настоящее время разрабатывают новую сеть мониторинга AQ для достижения беспрецедентного разрешения по оценке уровней качества воздуха. В частности, европейский Решимость Союза в улучшении, начиная с уровня городов, АК на всей своей территории подпитывали 5 инновационных проектов, основанных на развертывании высокой плотности интеллектуального AQM системы (сайт MAY AQ, 2020 г.). Однако это может быть достигнуто только путем компромисса с плотностью измерений с потерей точности на уровне одного устройства (Lewis et al., 2016). Несмотря на значительные исследовательские усилия за последние пять лет, в ходе которых полевые исследования показали, что их производительность постепенно достигла удивительного уровня, они все еще чтобы соответствовать строгим требованиям неопределенности, которые квалифицировали бы их для использования в качестве ориентировочных системы измерения (Borrego et al., 2016; EU AQ Directive, 2008). Несмотря на их более высокие относительные затраты по отношению к устройствам датчика оксида металла, электрохимические датчики подтвержден как наиболее перспективный в долгосрочной перспективе развертывание сетевой AQMS. Недорогие датчики на самом деле подвержены ряду технологических проблем, в том числе линейность и помехи от известных (или даже неизвестных) нецелевых газов и условия окружающей среды (Cordero et al., 2018; Cross et al., 2018;). Кроме того, химические датчики реагируют на их целевой газ и нецелевой газ, а также на окружающую среду помехи могут быть нелинейными. Полезным примером является влияние температуры в Реакция недорогих электрохимических сенсорных устройств (техническое описание датчика Alphasense NO₂, 2020 г.). Дисперсия, вызванная производственным процессом, определяет чувствительность и реакцию нулевого газа на значительно различаются от одного устройства к другому, что приводит к необходимости отдельной калибровки все без исключения химические (мульти)сенсорные устройства. Наконец, функция отклика может изменяться во времени. для известных и неизвестных эффектов, таких как отравление сенсора, из-за длительного воздействия значительные концентрации целевого газа или старение (Marco and Gutierrez-Galvez, 2012).

Следовательно, калибровка этих систем имеет решающее значение для оценки и подтверждения их эффективности.

чтобы их можно было уверенно использовать для получения значимой информации о AQ в городах.

(Боррего и др., 2018). К сожалению, количество условий, которые необходимо воспроизвести в

Настройка контролируемой атмосферы, чтобы полностью понять химическую мультисенсорную реакцию, настолько высока в настоящее время препятствует использованию (длительных) лабораторных процедур калибровки. Управляемые полевыми данными многомерная калибровка с использованием AQRMS в качестве наземной истины может значительно уменьшить влияние

известных помех путем обучения моделей, которые могут устранить их нелинейные воздействия на датчик отклик. Модель машинного обучения показала себя лучшим кандидатом на бортовое или дистанционное управление.

калибровка массива химических датчиков, работающих в сценариях мониторинга качества воздуха (Borrego

и др., 2018 г.; Эспозито и др., 2016). Однако неизвестные помехи могут играть скрытый контекст

роль, отрицательно влияющую на устойчивость модели к меняющимся условиям. Атмосферное поле

условия на самом деле нестационарны, и достоверность моделей машинного обучения может со временем исчезнуть

в связи с сезонными изменениями антропогенных выбросов и условий окружающей среды, а также

Конечно, датчики дрейфуют (Masey et al., 2018, De Vito et al, 2012). Этот параметр известен в

сообщество машинного обучения как обучение в динамической среде, и может быть решено

с различными методологиями, включая частую повторную калибровку, объединение сезонных классификаторов,

полууправляемое обучение и т. д., адекватно реагирующие на обнаружение изменений (Ditzler et al.,

2015). Вышеупомянутая особенность химического сенсорного поля, в частности

отклонения в производстве, старение датчиков и ограниченный срок службы блоков химических датчиков, потребности в рекламе

специальные подходы. На самом деле, процедуры повторной калибровки могут значительно снизить потери

точность из-за общего дрейфа концепции, но высококачественные размеченные данные обычно доступны только

во время начальной калибровки. Высокая стоимость повторного сбора инструментов и ожидания повторного

время калибровки, однако, является фактором торможения для коммерческих предприятий и клиентов.

Следовательно, нам нужно прибегать к специальным процедурам, которые используют любое событие, будь то

случайным или заранее запланированным, чтобы совместить, по крайней мере, на короткое время, одно устройство низкой точности с

тот, который может улучшить свою производительность на основе точных показаний целевых концентраций.

Этот подход обычно называют (повторной) калибровкой от узла к узлу или рандеву.

Хазенфрац и др. впервые применил онлайн-алгоритмы для повторной калибровки на основе рандеву.

в сетях мониторов качества воздуха (Hasenfratz et al., 2012). Они использовали фиксированный периодический схема повторной калибровки с узлами, получающими регулярные 40-минутные периодические обновления для своих полиномиальные одномерные калибровочные параметры. Сравнивали три модели обновлений среди который взвешивает прошлые калибровочные кортежи, фактически реализуя настраиваемое забывание механизм, направленный на борьбу со старением сенсора. Используются только датчики с последней калибровкой в качестве источников информации для калибровки между узлами (N2N). Полевые результаты с использованием двух совмещенный датчик O₃ MOX и смоделированные реплики указывают на значительное улучшение Показатели средней абсолютной погрешности (MAE) благодаря оперативной калибровке N2N в течение 6 недель долгое развертывание. Арфайр и др. использовали набор данных OpenSense для статистического определения фиксированная, но реалистичная схема калибровки случайных рандеву для автобусов общего пользования установленный AQMS на основе автобусных маршрутов (Arfire et al., 2015). Использование колокации на десять месяцев экспериментах они использовали инструмент нормативного класса для калибровки сенсорного устройства CO коррективка температурных помех с использованием нескольких моделей функций калибровки. Они сделали не сравнивать характеристики с классической автономной схемой начальной калибровки, которую они не использовали, но продемонстрировали положительное влияние калибровки рандеву всякий раз, когда входящий поток данных настраивался под сложность модели. Используются только новые образцы. генерировать обновленную калибровку, фактически не сохраняя память о предыдущей калибровке параметры. Кизел и др. Теоретически и экспериментально изучали распространение ошибок. во время процедур одномерной калибровки от узла к узлу в сетях AQMS (Kizel и др., 2018). Они показали возможность гарантировать сохранение уровня ошибки в заданный диапазон за счет точного проектирования длины цепи калибровки. Сосредоточение внимания на O₃ и NO они экспериментировали с фиксированной схемой рекалибровки со сроком 3 недели и колокейшн продолжительностью одна неделя при различных сценариях в течение максимум 3 месяцев. Оптимальные результаты где получено сохранение многоскачковой цепи длиной ≤ 2 скачков. Другой подход может полагаться не на физическое совместное размещение, а на удаленный обмен информацией. На самом деле, это могло основываться на постоянном или периодическом наличии потока целевого газа высокой точности оценки концентрации, спроецированные в месте расположения мультисенсоров с помощью геостатистического картографирования AQ алгоритм или модель, использующая информацию, полученную от соседних узлов сети

чтения. Этот подход можно обозначить термином калибровка сети (NC). Мискелл и др.

др. недавно показали результаты, полученные с помощью простой, но эффективной процедуры (Miskell et al.,

2018). Один новаторский пример этой стратегии уже был описан Tsujita et al., который

обновили свои сетевые параметры отклика датчиков NO₂, используя образцы с

очень низкие концентрации ожидаются ночью при определенных погодных условиях (Tsujita et al.

др., 2005). Стратегии калибровки сети обычно нацелены на стационарные станции, контролирующие AQ.

параметры с временным разрешением в часовом диапазоне, обычно получаемые путем усреднения минутных

данные разрешения. Особый случай представляет использование недорогих мультисенсоров.

устройство в качестве резервной станции, которая постоянно находится рядом с анализаторами нормативного уровня

станция с целью предоставления резервных данных, когда обычные анализаторы выключены

линия. Станции регулирующего мониторинга AQ (AQRMS) на самом деле страдают от периодических сбоев.

и подвергаются частым операциям по техническому обслуживанию, которые отключают их. Это вызывает

данные будут отсутствовать в течение нескольких периодов времени в течение года, что затрудняет проверку достоверности

краткосрочные и долгосрочные оценки AQ в городском и региональном масштабе. Недорогие мультисенсоры

Таким образом, устройство может позволить изящно снизить производительность, но при этом получать данные в

это нежелательное, но, к сожалению, частое состояние (De Vito et al., 2019).

Ни один из этих подходов не тестировался для долгосрочного развертывания (например, > 1 года).

в то время как они в основном сосредоточены на схемах N₂N и одномерных калибровках. Как упоминалось ранее,

многомерная калибровка имеет решающее значение для использования потенциала сбора информации о химическом веществе.

массив датчиков и уменьшить ошибку, вызванную помехами. Комплексный и экспериментальный

исследование влияния частоты и объема обмена информацией в сети

подходов к калибровке по-прежнему не хватает. Поэтому в этой статье мы сосредоточим наши усилия на

тестировать адаптивные многомерные стратегии машинного обучения в нестационарных условиях поля

эксплуатации мультисенсорных устройств качества воздуха в течение длительного времени. Использование поступающих данных

из текущего эксперимента по совместному размещению, который сейчас длится 18 месяцев, мы протестируем адаптивный

и стратегии постепенного обучения для повышения точности первоначально откалиброванного

устройство датчика стоимости, предназначенное для оценки загрязняющих веществ CO, NO₂ и O₃. Различные периодические

калибровочные схемы тестируются для выяснения зависимости производительности от повторной калибровки

период и количество обновленных калибровочных кортежей. Результаты помогут улучшить нашу знания о производительности, достигаемой узлами резервного монитора, а также сеть или стратегии непрерывной перекалибровки между узлами.

2. Экспериментальные настройки

2.1. Архитектура узла с несколькими датчиками качества воздуха IoT

В этом исследовании мы полагаемся на использование системы ENEA MONICA AQMS, предназначенной для совместной мобильные операции по количественному зондированию качества воздуха. Устройство МОНИКА основано на массив электрохимических датчиков с использованием сенсорных блоков Alphasense™ класса A4, соответственно нацелены на угарный газ, двуокись азота и озон. Относительная влажность (RH) и

Датчики температуры дополняют набор датчиков. Предусмотрен аналоговый интерфейс датчиков

той же компании и позволяет подключать датчики к микроконтроллеру ARM на базе ST

Микроэлектронная плата Nucleo. Последний захватывает и оцифровывает два соответствующих датчика.

клеммные напряжения каждого датчика, а именно рабочего (WE) и вспомогательного электродов (AE),

вместе с показаниями температуры и относительной влажности с сенсорного устройства SHT11. Необработанные данные датчиков захватываются 10-битным АЦП и передаются через последовательный интерфейс Bluetooth на Raspberry.

Пи Мод. 3+ приемник данных с ОС Raspbian, обеспечивающий локальное хранилище и глобальную сеть услуги связи через соединение 3G. Данные записываются со скоростью 10 выборок в минуту.

На удаленной стороне специальная серверная архитектура IoT, основанная на содержащихся REST API Nodejs.

сервер и MongoDB обеспечивают ввод данных, управление устройствами, хранение, предварительную обработку и функции визуализации на основе карт. В этом исследовании загруженные данные усредняются по

почасовая, чтобы сравнивать с почасовыми данными, выдаваемыми эталонными инструментами.

2.2. Запись набора данных

Устройство MONICA с апреля 2018 года находится на улице Via Argine (Неаполь, Италия) вдоль главная дорога, соединяющая Неаполь с несколькими городами в районе горы Везувий в совместном расположении со станцией анализаторов нормативного качества.



Рис. 1: Три устройства MONICA в наружном корпусе (вверху).

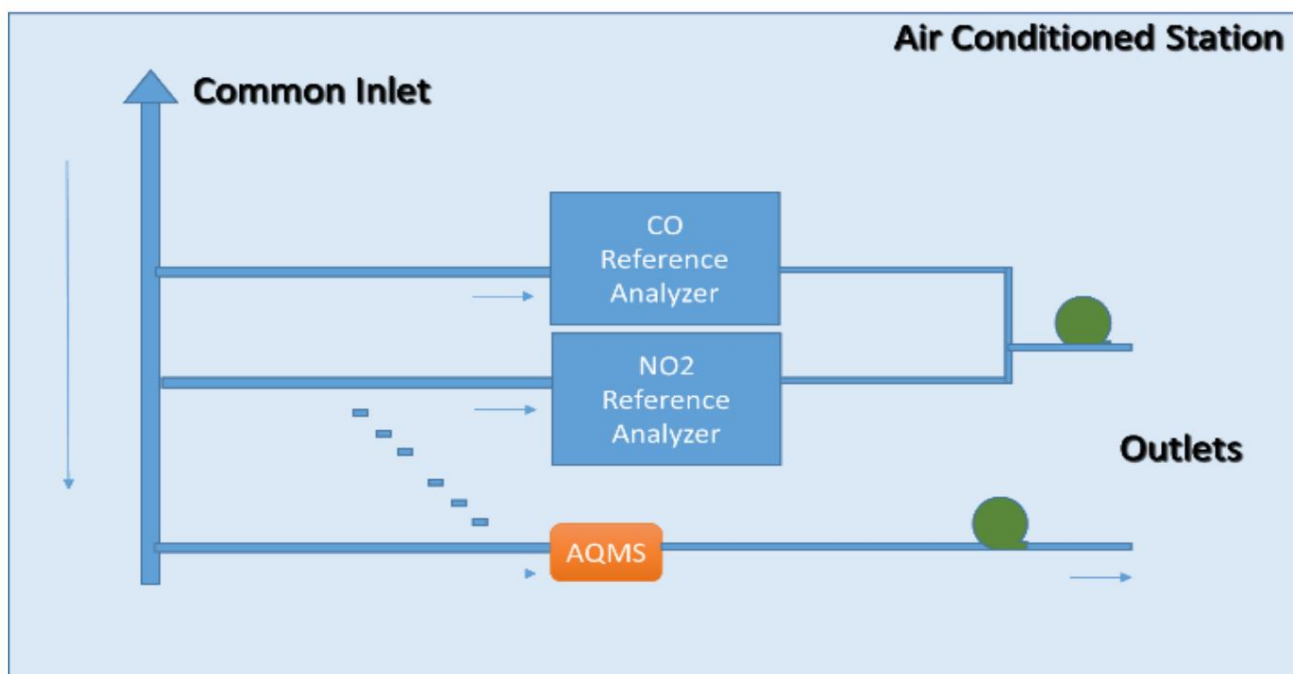


Рисунок 2: Схема подключения, показывающая, что устройство MONICA питается от общего входа Станция АРПАК.

Последний фактически находится в ведении Регионального агентства по охране окружающей среды Регион Кампания (ARPAC) и является частью официальной регулирующей сети мониторинга AQ, как таким образом, он подвергается регулярному техническому обслуживанию. Его схема развертывания включает в себя

Анализатор CO Teledyne™ 300, хемилюминесцентный анализатор NO₂ Teledyne T200, BTEX

анализатор и анализатор твердых частиц (PM_{2,5} плюс PM₁₀). В отличие от других ко

исследования местоположения, наш вход AQMS напрямую подключен к основному общему входу

AQRMS (см. рис. 1). Общий вход гарантирует, что один и тот же поток воздуха достигает всех нормативных

инструментов и прибор МОНИКА. Установка на самом деле предназначена для ограничения любого

помехи, возникающие из-за различий в анализируемом эфире в реальном времени, которые обычно обнаруживаются в

общие развертывания совместного размещения. Записанный набор данных состоит из 6864 почасовых выборок.

зарегистрировано с апреля 2018 года по июль 2019 года. Несмотря на наличие кондиционера

(AC), внутренняя часть опорной станции претерпела значительные температурные колебания

(см. рис. 3), пики которой в июле 2018 г. иногда достигали 38°C из-за неправильной настройки

система. В частности, набор данных содержит усредненные почасовые данные с устройства, т.е.

Необработанные показания датчиков рабочего электрода (WE) и вспомогательного электрода (AE) (мВ) для NO₂, CO,

O₃ плюс температура (°C), влажность (%), объединенные с почасовыми усредненными данными от ARPAC.

эталонный анализатор для NO₂ (ppb), CO (ppm). В частности, показания вспомогательного электрода

может использоваться для частичной коррекции температурных помех, влияющих на эти датчики WE. Это

фактически представляет собой двойной электрод, поверхность которого никогда не соприкасается с загрязняющим веществом, в то время как

еще под влиянием температуры. Из-за их особой геометрии и изготовления

сложности, влияние температуры на показания разных электродов различно и

температура еще влияет на их разницу (WE-AE) которая кстати остается производителем

рекомендуется лучший входной сигнал для одномерной калибровки этих датчиков (см. Датчики

Техническое описание в справочном разделе). Результаты, полученные в разделе процедуры калибровки

основное внимание будет уделено NO₂, в то время как справочные данные по O₃ отсутствуют. На рис. 4 месячная ящичковая диаграмма

Показана динамика истинной концентрации целевого газа NO₂ и CO по всему набору данных. В

На рис. 5 показаны временные ряды NO₂ и CO, демонстрирующие наличие пробелов в данных из-за

к сбою подключения BT из-за недокументированных ошибок в библиотеках BT для Raspbian. То

набор данных был предварительно обработан, анализ отсутствующих значений, обнаружение возможных выбросов

при этом был проведен корреляционный анализ. В частности, для обнаружения выброса,

Был применен алгоритм DBSCAN, удаляющий 72 аномалии во всем наборе данных. Этот

немного улучшена корреляция между данными о целевом газе и данными датчиков. Рис. 6 показать месячное распределение вероятностей целевого и основного целевого датчика NO₂ показания с поправкой на температуру (AE-WE) вместе с их коэффициентом корреляции.




Рисунок 3: График месячных температур по набору данных. Выбросы изображаются одиночными точками.




Рис. 4: Ежемесячная ящичковая диаграмма поведения эталонной концентрации NO₂ (ppb) по набору данных. Выбросы изображаются одиночными точками.

2.3. Стратегии калибровки

Как упоминалось выше, необработанные данные массивов химических датчиков должны обрабатываться функцией калибровки для точной оценки концентрации целевых газов с учетом линейности и помехи. Как правило, функция статической калибровки может быть выражена следующим образом:

$$y = (x_1, \dots, x_n) + \epsilon(1)$$

Где y – наблюдаемые показания датчика, f – функция f значений вектора параметров и ϵ неизвестный член ошибки. На самом деле информация об обоих мишенях (y) и известные не целевые мешающие газы (x_1, \dots, x_n) помогает построить более полную модель отклика сенсора.




Рис. 5: Наземные временные ряды истинности NO2 (млрд) с использованием функции интерполяции LOESS.

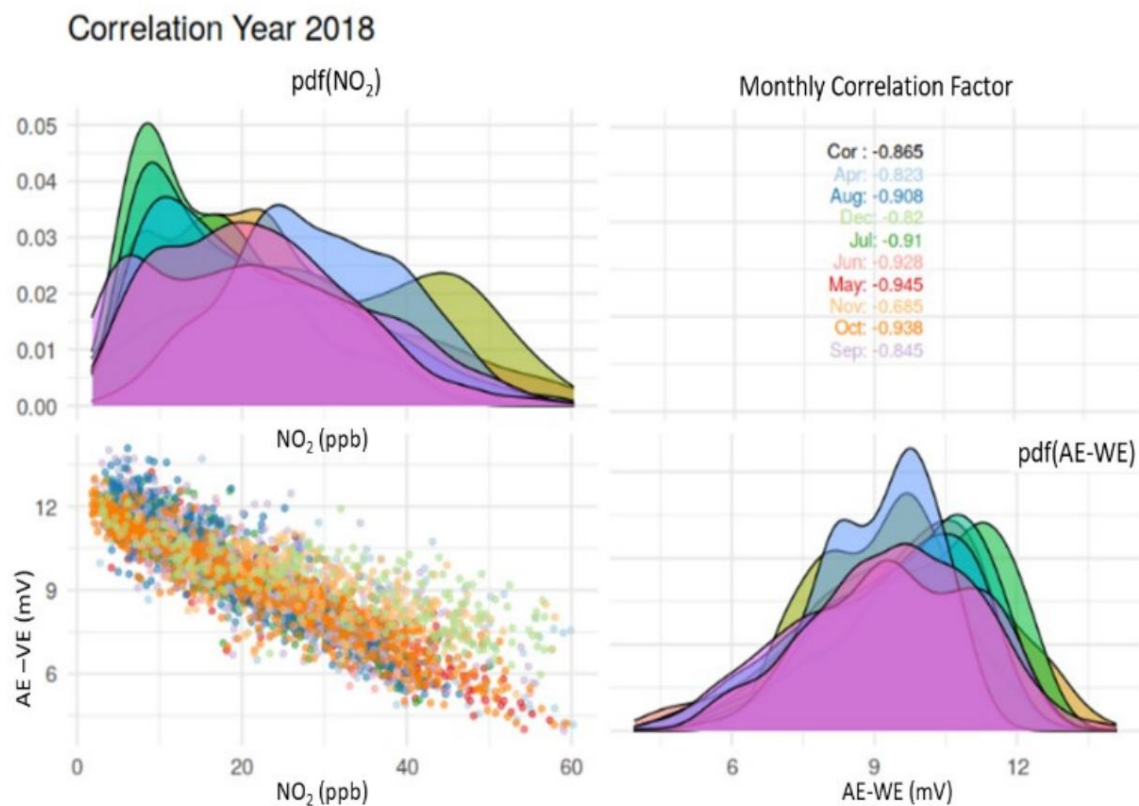


Рисунок 6. Коэффициенты корреляции Пирсона между заданной концентрацией газа NO₂ и необработанными показаниями датчика NO₂ (разница AE-WE), рассчитанные для каждого месяца в 2018 г. (правый верхний угол), ежемесячная эмпирическая pdf (верхний левый угол для NO₂ и нижний правый для AE-WE) и точечная диаграмма среди вышеуказанных переменных (нижний левый угол). Разные цвета связаны с разными месяцами. Очевидны значительные сезонные отклонения и изменения чувствительности. Мы советуем пользователю обратиться к онлайн-версии этого документа для лучшей удобочитаемости.

Количество наблюдаемых может быть завершено с использованием прошлых записей входных данных и выходы с использованием ответвленных линий задержки, чтобы справиться с динамическими и некоррелированными датчиками шум, воздействующий на эти нелинейные изменяющиеся во времени динамические системы (Esposito et al., 2016). К используя записанные в полевых условиях данные, методология полевой калибровки создает обучающую выборку, которая на самом деле отражает полевые оперативные условия с точки зрения состава атмосферы и окружающей среды настройки. Однако это состояние может быть изменено появлением во времени понятия дрейфует, заставляя конкретную функцию калибровки работать вне границ ее обучения многообразие, что снижает общее качество результатов.

В частности, алгоритмы полевой калибровки усложняются изменениями совместной вероятности. распределение откликов сенсоров и концентраций их возбудителей:

$$(\tilde{y}, \tilde{c}) \quad (2)$$

На самом деле, старение и загрязнение сенсоров влияет на чувствительность сенсоров и базовый отклик. в то время как сезонные изменения экологических и антропогенных воздействий влияют на целевой газ С концентрация, известные или неизвестные нецелевые мешающие газы концентрации, а также значения температуры и влажности (E), которые действуют как скрытый контекст, в конечном итоге изменяя условное распределение вероятностей:

$$(\tilde{y} | \tilde{c}) \quad (3)$$

Явно заботясь о соответствующих значениях переменных среды, калибровка функции (см. уравнение 1) можно обучить корректировать их влияние:

$$= (\tilde{y}, 1, \dots, \tilde{c}) + h \quad (4)$$

но, опять же, сезонные изменения в их распределении могут привести к тому, что изученная модель станет неполный. Измерение ненаблюдаемых помех h по определению полностью за пределами нашего понимания.

Подводя итог, можно сказать, что изменения в собственной модели датчика или распределении форсирующих факторов делают недействительным изученная функция калибровки по соответственно несогласованности или неполноте. Если новый становятся доступными помеченные образцы, стратегии онлайн-обучения, как поэтапные, так и адаптивный характер, может быть использован для исправления этих проблем. Однако катастрофическое забвение или могут возникнуть интерференционные эффекты. Для этой цели мы выбрали два алгоритма, а именно стандартная неглубокая, прямая связь, нейронная сеть (SNN) и машина для экстремального обучения (ELM), чтобы поэкспериментировать, соответственно, с двумя методологиями (пошаговое онлайн-обучение и обновление).

В частности, неглубокие нейронные сети уже доказали свою эффективность в полевых условиях.

калибровка мультисенсорных систем AQ, в то время как ELM почти не использовались в таких сценариях.

ELM — это простые архитектуры с прямой связью, которые используют случайное расширение функций в

первый слой и полностью связанный линейный выходной слой. Основная идея была

исследуется десятилетиями и является одной из ключевых основ компрессионного восприятия (Huang et al., 2006). Кажется, что они имеют архитектурное сходство с мозгом млекопитающих и быстро несутся.

преимущества вычислений, обеспечивая хорошие результаты, особенно когда небольшой набор данных касается, по сравнению с лучшими алгоритмами класса.

В этой статье мы сосредоточились на задаче оценки концентрации NO₂ с использованием датчики электрода (WE) и вспомогательного электрода (AE) данные датчиков NO₂, O₃ и CO плюс данные о температуре и влажности в качестве входных данных для двух компонентов машинного обучения:

2, 2, 2, 3, 3,)

Используя предыдущие результаты в аналогичных сценариях (см. De Vito et al., 2018), число

скрытые нейроны для обеих архитектур были заданы так, чтобы располагаться в фиксированном диапазоне. SNN

архитектура была эмпирически оснащена [3,5,7] стандартными сигмоидальными касательными нейронами

в своем единственном скрытом слое, а последний слой был снабжен линейным выходным слоем.

В качестве алгоритма обучения использовалась автоматическая байесовская регуляризация (ABS). Тот самый

конфигурация входов использовалась для ELM, архитектура которого включала [15,25,45] радиальные

базисных нейронов скрытого слоя и линейного выходного слоя. Во время первоначального обучения

оценок количество скрытых нейронов в обеих архитектурах было оптимизировано при сканировании

указанный выше набор значений. Полученные значения составили 3 и 15 соответственно для SNN.

и архитектура ELM. Первые 4 недели записей были извлечены, чтобы обеспечить первоначальный

автономный калибровочный набор, а именно TI, для двух обучаемых компонентов ML (SNN, ELM). То

25% калибровочного набора было использовано для целей ранней остановки с количеством

последовательных событий снижения производительности, эмпирически установленных на уровне 10. После этого два

функции калибровки были адаптированы с использованием различных шаблонов периодичности и обновления

(ввод, метки) количество кортежей (см. рис. 7). В частности, периодичность обновления калибровок

τ был выбран из следующего набора:

$$\tau T = [2, 12, 24, 120, 240, 720, 2160] \text{ часов}$$

на самом деле колеблется от двух часов до трех месяцев, в то время как количество доступных обновлений кортеж π был выбран из следующего набора: $\pi P = [1, 4, 12, 24, 120, 168]$ часов. Конечно, только подмножество шаблонов в $T \times P$ с $\pi < \tau$ было правдоподобным и, следовательно, было выбрано для тестирования. целей. Обновляемый выбор кортежа производился как по регулярному расписанию (т.е. образцы нового периода T) или равномерно выбранные из кортежей нового периода T , имитирующие оппортунистические обновления.

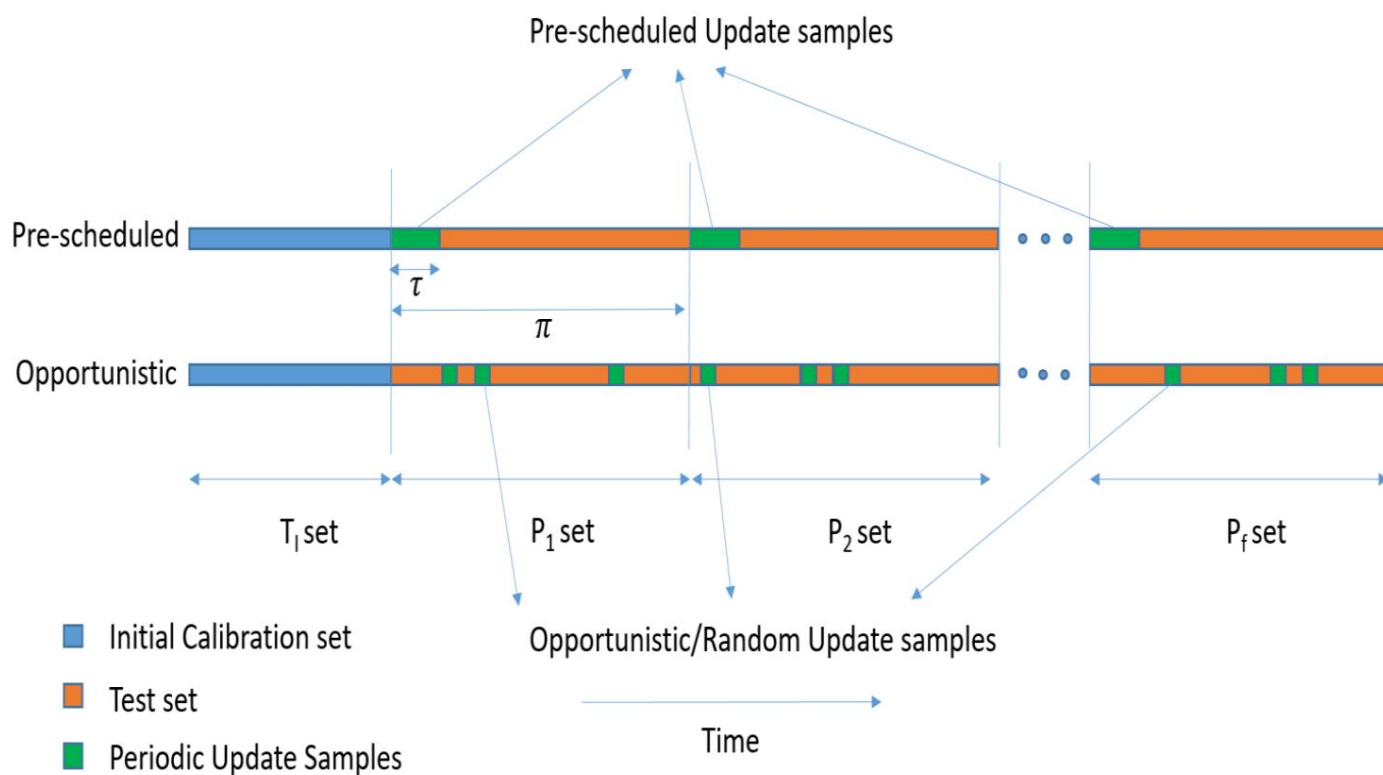


Рис. 7. Процедура цикла обучения/обновления/тестирования, показанная как для обычных, так и для запланированных программ. Возможные/случайные сценарии обновления.




Рисунок 8: Схема проверки: 4 недели подряд были выбраны в качестве начальной продолжительности тренировочного набора. Четыре были реализованы повторения процедур обучения/обновления/тестирования с использованием 4 разных начальных моментов для калибровочные наборы. Показатели эффективности были усреднены между ними, чтобы снизить производительность зависимость от выбора конкретных выборочных наборов.

Практически SNN просто переобучалась каждые t часов, используя увеличивающийся набор данных. (постепенный подход, впоследствии названный iSNN), включающий набор T_I , а также прошлые и новые входящие помеченные кортежит. В качестве обучающего алгоритма снова использовался ABR с фиксированным максимумом. количество эпох обучения (500). Вместо этого первоначально калиброванный набор выходных весов ELM обновлялся с использованием тех же кортежей (метод обновления). Конечно, обновление ELM процедура обеспечила более быструю адаптивную стратегию с фиксированным и предсказуемым вычислительным Стоимость. С другой стороны, вычислительные затраты на повторное обучение SNN (и, следовательно, необходимое время) постепенно росла с увеличением размеров добавочной обучающей выборки. Для обоих компонентов выборки каждого нового периода оценивались с использованием обновленного результаты калибровок и стали частью тестовых данных по оценке концентрации. Вместо, выборки до последнего входящего обновляющего кортежа концентрации были оценены с использованием прошлых калибровки и интегрированы в данные оценочных испытаний. Оценки и истинные концентрации следовательно, были сравнены для оценки производительности. Средняя абсолютная ошибка (MAE), среднее

Относительная ошибка, нормализованная MAE (MAnE), RMSE и nRMSE использовались в качестве производительности.

оценщики. Полученные результаты также сравнивались с результатами, полученными при первоначальном

4 недели обучения SNN в автономном режиме и с помощью многомерной линейной модели, обученной с теми же значениями

и используя обычную схему оптимизации параметров методом наименьших квадратов. Чтобы уменьшить

зависимости производительности от начального 4-недельного калибровочного набора, мы повторили

эксперименты 4 раза с разным временем начала через [0 нед, 2 нед, 4 нед, 6 нед]

фактически используя следующие 5075 образцов для обновлений и целей тестирования (см. рис. 8). 5075

на самом деле это самый большой размер выборки, гарантирующий одинаковый размер тестового набора для всех калибровок.

наборов при настройке запускать сразу после окончания самих калибровочных наборов. Исходный

результаты обучения были усреднены 10 раз для уменьшения зависимости от случайного

инициализация весов в двух архитектурах нейронных сетей.




Рисунок 9: Результаты одного из 4 экземпляров начального обучающего эксперимента для лучшего набора гиперпараметров (остальные 3 экземпляра см. в разделе дополнительных материалов). Жирные линии

вычисляются с помощью симметричного фильтра сглаживания скользящей средней продолжительностью 96 часов.

3. Результаты

3.1. Стратегия начальной калибровки

Первоначальный эксперимент по стратегии калибровки был проведен с целью обеспечения понимание базового уровня производительности, достижимого с помощью современной методологии.

Для наилучшего набора значений гиперпараметров усредненные результаты представлены в таблице 1:

Таблица 1. Сводка различных показателей эффективности, рассчитанных после первоначальной калибровки и для последовательные 5075 проб.

	МАЭ <small>(частей на миллиард)</small>	MAHE	MRE	RMSE		НМСЭ <small>(частей на миллиард)</small>
Линейная	7,49 0,075	0,53 10,44	0,80			
ЭЛМ	8,63 0,087	0,63 11,46	0,88			
СНН	7,43 0,075	0,53 10,72	0,82			

Синтетические индексы показывают, что производительность полилинейной модели и модели SNN была очень высокой. аналогично, в то время как ELM был немного неэффективным. Тщательный анализ МАЭ производительность с течением времени ясно указывает на то, что все модели постепенно теряют свою достоверность. ухудшение показателей абсолютной ошибки по отношению к неделям сразу после периода обучения (см., например, рис. 9, начиная с октября 2018 г.).

3.2. Стратегии адаптивной калибровки

Различные ТхР, которые были рассмотрены, представляют очень разные сценарии обновления калибровки. На самом деле комбинация (2,1) представляет развертывание сценарий, в котором узел фактически постоянно совмещен с высокой точностью инструмент, а именно инструмент нормативного уровня и, следовательно, работающий в качестве резервной системы для преодоления периодов отказов станций нормативного уровня. С другой стороны, (720 168) представляет собой систему, которая перекалибруется каждый месяц с преимуществом одного целую неделю калибровочных кортежей высокой точности. Промежуточные сценарии, такие как, например,

(24,1) может быть репрезентативным для калибровки сети на основе модели, выдающей регулярные или, случайные/оппортунистические (или даже тщательно отобранные на основе конкретных обновлений, основанных на особые условия. В дополнение к предыдущему сценарию (24, 4) может быть репрезентативным AQMS, установленная на автомобиле, автобусе или грузовике, которая намеренно получает нормативный уровень совместное размещение приборов в нерабочее время. Расширение «на лету» от узла к узлу сценарий калибровки может и должен быть тщательно проработан из-за минимального периода колокации одного часа для большинства сценариев случайных обновлений.

Таблица 2. Сводка усредненных результатов MAE (ppb) периодических инкрементных экспериментов SNN (iSNN) вдоль различных комбинаций TхP.

	T=2 часов	T=12 часов	T=24 часов	T=240 часов	T=720 часов
P=1 час	3,76	4,03 4,26		5.33	6,55
P=4 часа	-	3,64 3,90 4,92			6,35
P=12 часов	-	-	3,59 4,45		5,85
P=24 часа	-	-	-	4,27	5,46
P = 168 часов	-	-	-	3,96	5.09

В таблицах 2–5 показана часть полученных результатов в различных конфигурациях в обоих случаях. систематические и оппортунистические сценарии обновления, полные таблицы доступны как дополнительные материалы. В целом, как и следовало ожидать, наилучшие результаты были получены в случае, когда может быть реализована почти непрерывная модернизация. Для SNN это означало снижение почти на 50% MAE, полученной при начальном обучении. сценарий. Аналогичные результаты можно получить, начиная с различных соотношений T/P в зависимости от P. Для Например, в iSNN снижение на 40% может быть получено при P/T=1/24 для T=24, в то время как отношение

1/5 все еще недостаточно при $T=720$. Это означает, что и периодичность переобучения, и

частота наличия меченых образцов важна для получения оптимальных характеристик.

В целом, чем реже обновление калибровки, тем выше требуемое отношение P/T , т.е.

относительное количество помеченных образцов необходимо для получения аналогичных характеристик. Как

апгрейды и маркированные образцы становятся все более и более редкими, результаты приближаются к тем,

можно получить с помощью начальной калибровки. Результаты адаптивного ELM (aELM), как правило, заметно

результаты хуже, чем у их добавочных аналогов SNN (iSNN), но с учетом аналогичного

результаты, полученные в начальном сценарии обучения, это вполне может быть связано с более сильным

возможность представления, выраженная архитектурой SNN по отношению к архитектуре ELM.

Эти результаты очень похожи, но немного лучше результатов, полученных в оппортунистический/выборочный сценарий обновления, когда помеченный образец был доступен как распределены равномерно случайным образом. На рис. 10 графически показано сравнение различных стратегии результаты в случае использования первых 4 недель для начального обучения, $T = 24$, $P = 1$ и систематическое обновление. Наконец, на рис. 11 мы можем графически сравнить результаты, полученные при различное соотношение P/T для iSNN в сценариях оппортунистических и регулярных обновлений. В обоих случаях, редкое повторное обучение (более высокий T) приводит к ухудшению результатов даже при рассмотрении того же или равные частоты входящих обновлений (P/T).

Таблица 3. Сводка усредненных результатов MAE (ppb) периодически обновляемого адаптивного ELM (aELM) эксперименты с различными комбинациями $T \times P$.

	T=2 часов	T=12 часов	T=24 часов	T=240 часов	T=720 часов
P=1 час	3,74	4,68 5,83		6.09	7,62
P=4 часа	-	4,73 5,03		6,39	8,90
P=12 часов	-	-	4,63	6.20	6,78
P=24 часа	-	-	-	5,71	6.05
P = 168 часов	-	-	-	4,52	5,48

Таблица 4. Сводка усредненных результатов MAE (ppb) оппортунистического инкрементного SNN (iSNN) эксперименты с различными комбинациями TхP.

	T=2 часов	T=12 часов	T=24 часов	T=240 часов	T=720 часов
P=1 час	3,74	4,23	4,72	6,94	6,56
P=4 часа	-	3,73	3,97	5,27	6,31
P=12 часов	-	-	3,65	4,95	5,73
P=24 часа	-	-	-	4,56	5,40
P = 168 часов	-	-	-	3,93	4,99

Таблица 5. Сводка усредненных результатов MAE (ppb) периодического случайного обновления адаптивного ELM (aELM) эксперименты с различными комбинациями TхP.

	T=2 часов	T=12 часов	T=24 часов	T=240 часов	T=720 часов
P=1 час	4,47	5,78	5,90	7,54	8,6
P=4 часа	-	4,48	5,14	6,52	6,91
P=12 часов	-	-	4,70	6,03	7,43
P=24 часа	-	-	-	5,45	6,28
P = 168 часов	-	-	-	5,60	6,20

4. Выводы

В этой статье мы показали результаты, полученные с помощью различных обновлений калибровки. сценариев для преодоления эффектов дрейфа концепций, возникающих при многосезонном развертывании низких стоимость АКМС. Особое внимание уделяется калибровке сети и использованию онлайн-машинного обучения. компоненты, мы исследовали различные комбинации периодичности обновлений и количества поступающие образцы с маркировкой GT. Результаты показали возможность сильно улучшить

производительность, которую можно получить в течение более одного года с помощью развернутой в полевых условиях системы AQMS, получающей

регулярная или конъюнктурная информация из высокоточных помеченных источников данных.




Рисунок 10: Разница в показателях MAE для разных стратегий, рассчитанная по всему набору данных. Обратите внимание на преимущества как онлайн-обучения (iSNN, aELM), так и фиксированного подхода к начальному обучению.

(Млинейный, SNN). Жирные линии вычислены с помощью симметричного фильтра сглаживания скользящей средней продолжительностью 96 часов.

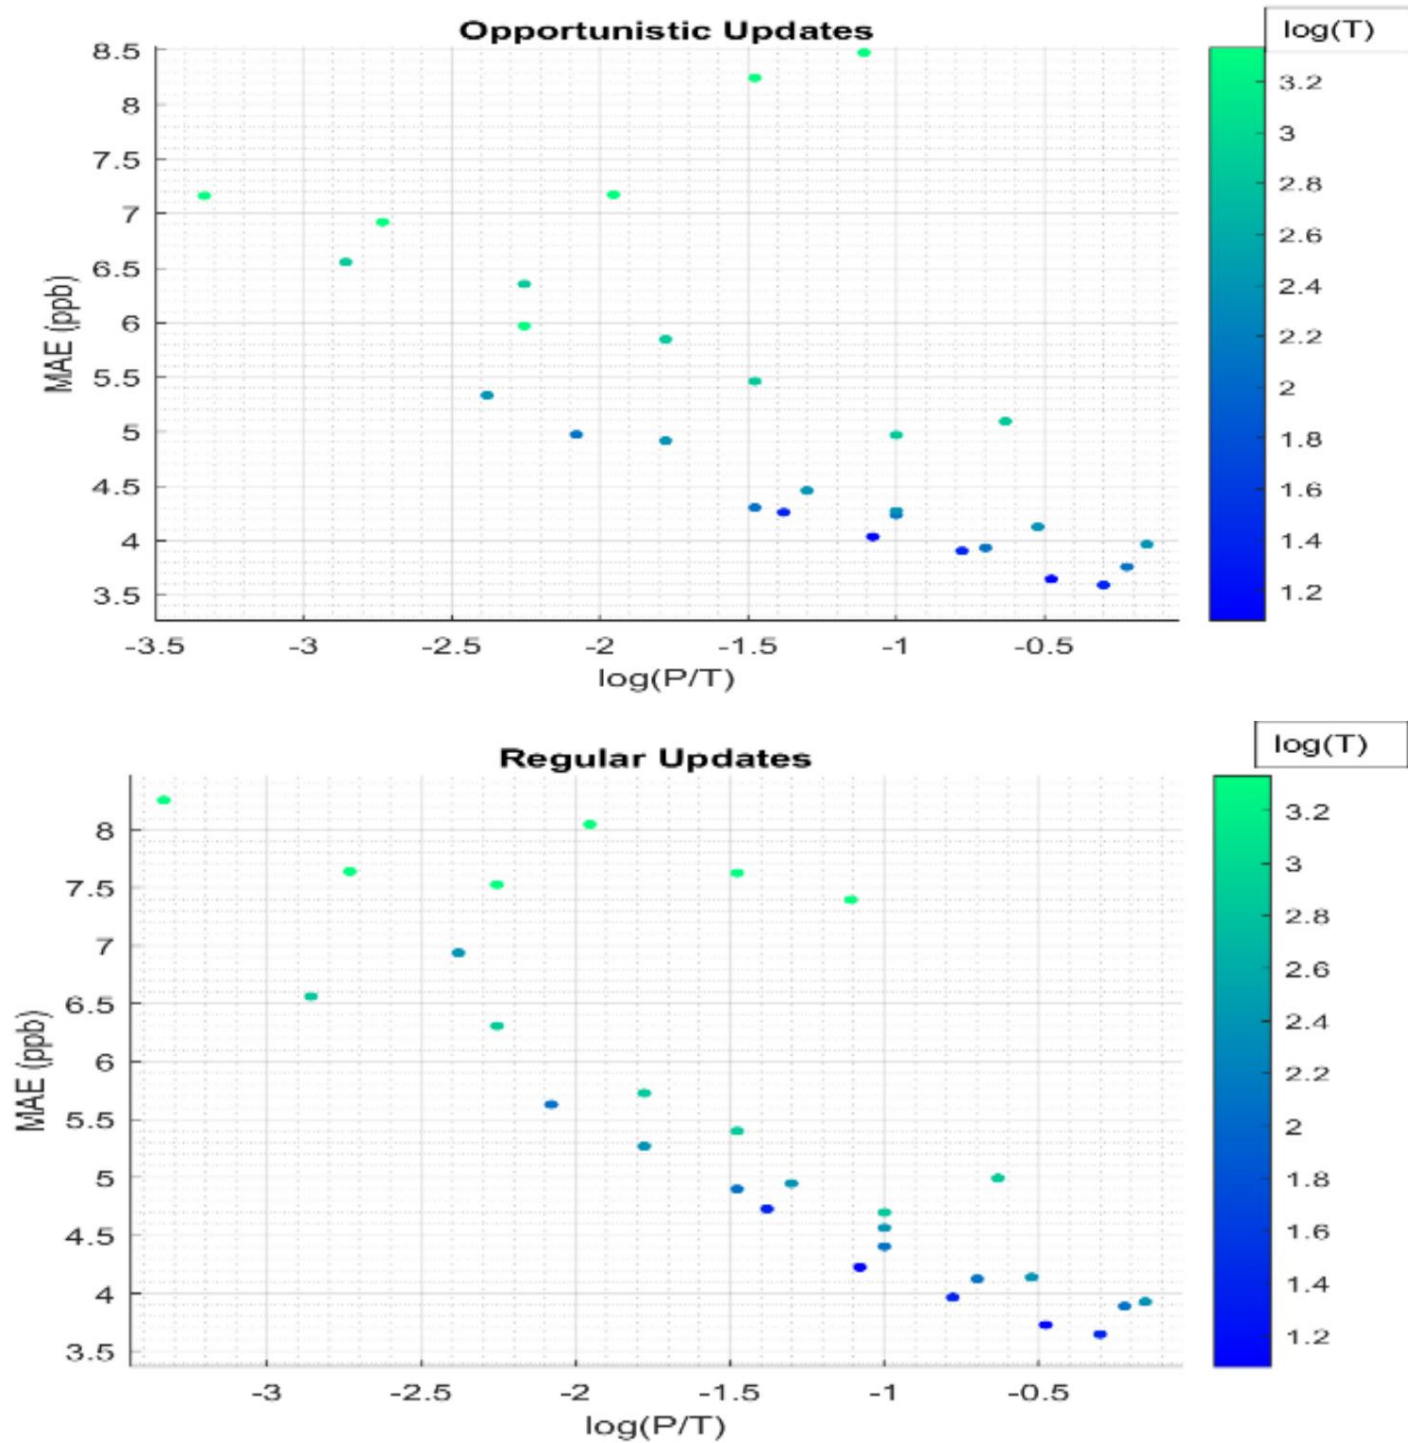


Рисунок 11: Сравнение производительности iSNN стратегий регулярного и оппортунистического обновлений при разных (Т,П) комбинации.

Кроме того, результаты указывают на актуальность как периодов обновления, так и количества помеченных образцы в определении окончательных характеристик. В частности, самые редкие обновления требуют более высокий процент помеченных данных для достижения тех же предустановленных целей производительности. А вероятный сценарий сетевых обновлений калибровки, т. е. ежедневные обновления с использованием одного час высокоточных данных, может достигать интересных обновлений только близко приближающихся результатов можно получить путем непрерывной калибровки. Для получения аналогичных результатов **ежемесячно** **для повторной калибровки может потребоваться до одной недели помеченных образцов почасовых данных.** Однако редко геостатистические модели могут соответствовать точности AQRMS, и необходима дальнейшая работа, чтобы полностью понимать влияние шумных обновлений на производительность периодически обновляемых развернутая в полевых условиях AQRMS.

Благодарности

Эта работа получила частичное финансирование ЕС в рамках 3- го конкурса MAU Project AirHeritage. Авторы выражают благодарность Региональному агентству по охране окружающей среды Кампании (ARPAC) за постоянная поддержка в процессе сбора данных.

использованная литература

- (Альфасенс NO2 Датчик Техническая спецификация) http://www.alphasense.com/WEB1213/wp_контент/загрузки/2019/09/NO2-A43F.pdf, посетили в январе 2020 г.
- (Арфайр и др., 2015) Арфайр и др., Калибровка рандеву мобильных сенсорных сетей на основе моделей для Мониторинг качества воздуха (2015 г.).
- (Borrego et al., 2016) С. Borrego, et al., Оценка микросенсоров качества воздуха по сравнению с эталоном методы: Совместные учения EuNetAir, Атмосферная среда, том 147, 2016 г., страницы 246-263.
- (Borrego et al., 2018) С. Borrego, et al., Оценка микродатчиков качества воздуха по сравнению с эталоном методы: Совместные учения EuNetAir – Часть II, Атмосферная среда, Том 193, 2018 г., Страницы 127-142.
- (Cordero et al., 2018) Хосе Мария Кордеро, Рафаэль Борге, Адольфо Наррос, Использование статистических методов для переноса калибровка в полевых условиях недорогих датчиков качества воздуха, датчиков и приводов В: Chemical, Volume 267, 2018 г., страницы 245–254, ISSN 0925–4005, <https://doi.org/10.1016/j.snb.2018.04.021>.

(Cross et al., 2018) Cross, ES et al., Использование электрохимических датчиков для измерения загрязнения воздуха: корректировка отклика на помехи и проверка измерений, Atmos. Изм. Тех., 10, (2017), 3575-3588.

(Де Вито и др., 2012) С. Де Вито и др., "Полуконтролируемые методы обучения искусственному обонянию: А Новый подход к проблемам классификации и противодействию дрейфу», в журнале IEEE Sensors Journal, том 12, № 11, стр. 3215-3224, ноябрь 2012 г.

(De Vito et al., 2018) S. DE Vito et al., Калибровка химических мультисенсорных устройств для реального мира приложения: подробное сравнение количественных подходов к машинному обучению, датчиков и приводов. В: Химическая промышленность, том 255, часть 2, 2018 г.

(Де Вито и др., 2019) С. Де Вито и др., «Адаптивное машинное обучение для резервного мультисенсора качества воздуха». Непрерывная калибровка систем», Международный симпозиум IEEE по обонянию и электронному носу, 2019 г. (ISOEN), Фукуока, Япония, 2019 г., стр. 1–4.

(Дитцлер и др., 2015 г.) Дитцлер, Грегори и др., (2015 г.). Обучение в нестационарных средах: обзор. Журнал вычислительной разведки, IEEE. 10. 12-25. 10.1109/МКИ.2015.2471196.

(Esposito et al., 2016) Э. Эспозито и др., Архитектуры динамических нейронных сетей для калибровка ориентировочных дорогих систем измерения качества воздуха, датчиков и приводов В: Chemical, Vol. 231, 2016, 701-713.

(Директива ЕС по качеству воздуха, 2008 г.) Директива ЕС по качеству воздуха, 2008 г. (Hasenfratz et al., 2012) D. Hasenfratz et al., «Оперативная калибровка дорогих датчиков газа», Wireless Сенсорные сети, стр. 228-244, 2012 г.

(Хуанг и др., 2006) Хуанг и др., Универсальная аппроксимация с использованием инкрементной конструктивной прямой связи Сети со случайными скрытыми узлами, Транзакции IEEE в нейронных сетях. 17 (4): 879-892

(Lewis et al., 2016) AC Lewis, P. Edwards, Проверка персональных датчиков загрязнения воздуха, Nature, 535, (2016), 29-31.

(Kizel et al., 2018) Fadi Kizel et al., Межузловая полевая калибровка беспроводного распределенного загрязнения воздуха сенсорная сеть, Загрязнение окружающей среды, том 233, 2018 г.

(Marco et al, 2012) С. Марко, А. Гутьеррес-Гальвес, Обработка сигналов и данных для машинного обоняния и Химическое зондирование: обзор, IEEE Sensor Journal 12 (11), 3189-3214

(Masey et al., 2018) Никола Мэйси и др., Временные изменения в отношениях полевой калибровки для Aeroqual S500 Мониторы на основе датчиков O3 и NO2, Датчики и приводы В: Chemical, 273, 2018, страницы 1800-1806.

(Miskell et al., 2019) Georgia Miskell et al., Надежные данные с дорогих датчиков озона в иерархической сеть, Атмосферная среда, том 214, 2019 г., 116870, ISSN 1352-2310, <https://doi.org/10.1016/j.atmosenv.2019.116870>.

(Tsuji et al., 2005) Wataru Tsuji et al., Сеть датчиков газа для мониторинга загрязнения воздуха, Датчики и Приводы В: Chemical, Vol.110, 2, 2005 г.

(веб-сайт МАУ, 2020 г.) <https://www.uia-initiative.eu/en/air-quality>, посетили в январе 2020.

ДОПОЛНИТЕЛЬНЫЕ МАТЕРИАЛЫ:

Таблица s1: Полные результаты подхода с инкрементным SNN (iSNN).

		T						
		2	12	24	120	240	720	2160
п		0	4,033	4,257	4,972	5,332	6,555	7.163
	1	0	3,645	3,90	4,301	4,915	6,353	6.922
	4	0	0	3,59	4,234	4,457	5,846	5.968
	12	0	0	0	3,932	4,271	5,460	7.173
	24	0	0	0	3,757 0	4,124	4,967	8.246
	120 168	0	0	0		3,964	5,093	8.476

Таблица s2: Полные результаты адаптивного подхода ELM (aELM).

		T						
		2	12	24	120	240	720	2160
п		0	4,684	5,829	5,652	6,094	7,620	8.069
	1	0	4,725	5,037	5,448	6,391	8,940	9.089
	4	0	0	4,634	5,661	6,197	6,782	9.067
	12	0	0	0	5,311	5,710	6,056	6.952
	24	0	0	0	4,734 0	5,469	6,008	6.265
	120 168	0	0	0		4,525	5,481	6.652


Стратегия оппортунистического обновления завершает результаты.

Таблица s3: Полные результаты подхода добавочного SNN (iSNN).

		T						
		2	12	24	120	240	720	2160
п		0 4,225 0		4,728	5,629	6,938	6,561	8.255
	1	3,728 0 0 0		3,966	4,899	5,269	6,307	7,639
	4 12	0 0 0 0		3,647	4,404	4,949	5,727	7,527
	24			0 0 0	4,125	4,564	5,400	8.046
	120				3,889 0	4,139	4,698	7,626
	168 0					3,927	4,993	7.396

Таблица s4: Полные результаты адаптивного подхода ELM (aELM).

		T						
		2	12	24	120	240	720	2160
п		0	5,783	5,904	7,449	7,536	8,610	8.832
	1	0	4,476	5,147	6,143	6,523	6,918	9,727
	4 12	0	0 0 0 0	4,694 0	5,265	6,033	7,438	9.466
	24 120 0 0			0 0	4,966	5,451	6,286	8.751
	168 0				5,381 0	4,699	5,996	8.635
						5,634	6,212	7,385



(a)




Рисунок s1: Ежемесячная диаграмма (a) и временной ряд, подобранный LOESS (b) поведения эталонной концентрации CO (ppm) по набору данных (a). Выбросы изображаются одиночными точками.




Рисунок s2: Полулогарифмический график средней относительной ошибки, рассчитанный при различных соотношениях P/T для сценария регулярного обновления и подхода iSNN. Более высокие отношения в сочетании с меньшими значениями T генерируют меньший MRE на протяжении всей продолжительности набора данных.

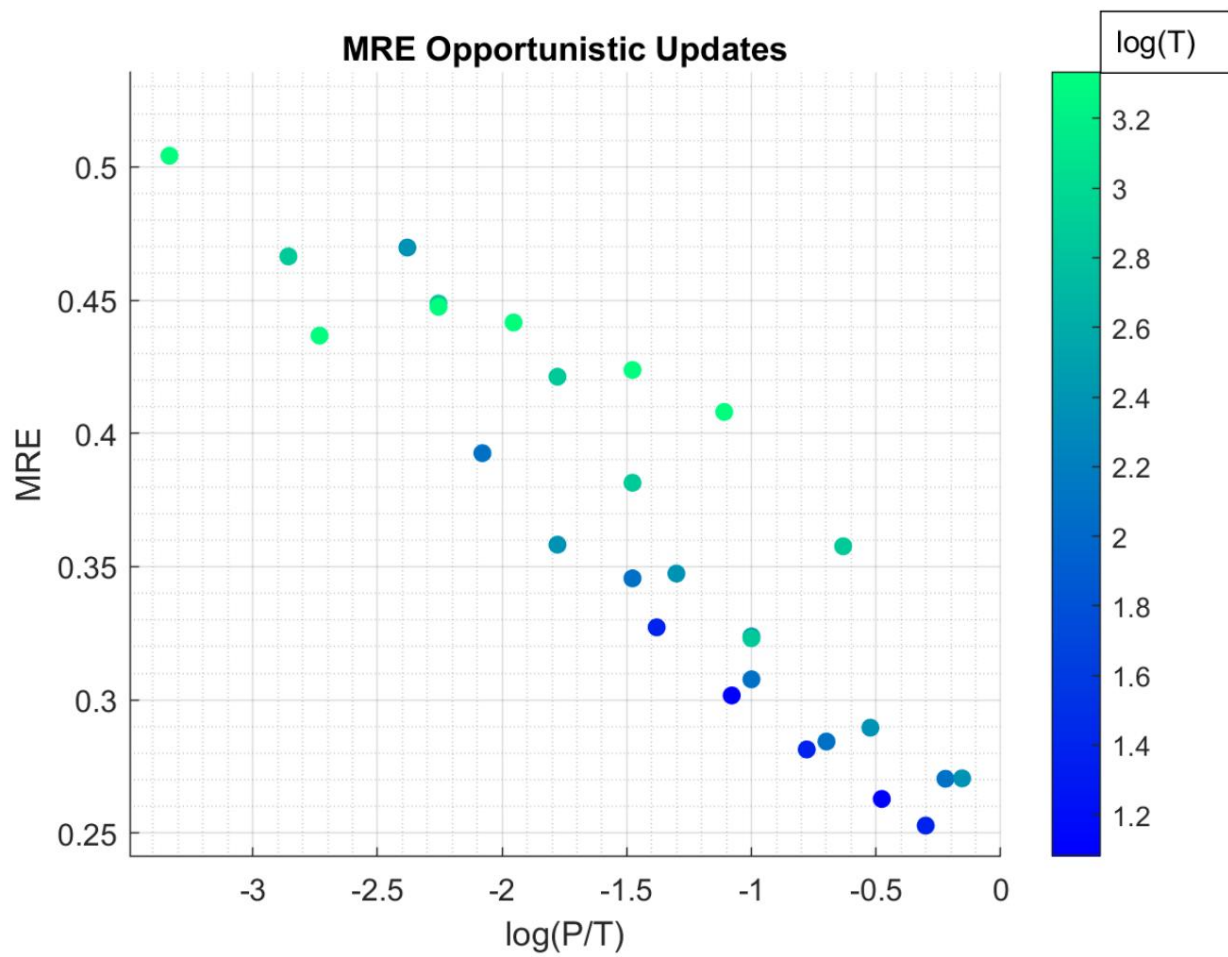


Рисунок s3: Полулогарифмический график средней относительной ошибки, рассчитанный при различных соотношениях P/T для сценария оппортунистического обновления и подхода iSNN. Более высокие коэффициенты в сочетании с меньшими значениями T генерируют меньший MRE по всему набору данных.




Рисунок s4: Результаты начального обучающего эксперимента (с 0 -й по 3-ю неделю) для лучшего набора гиперпараметров. Жирные линии вычислены с помощью симметричного фильтра сглаживания скользящей средней продолжительностью 96 часов.




Рисунок s5: Результаты начального обучающего эксперимента [с 4-й по 7-ю неделю] для лучшего набора гиперпараметров. Жирные линии вычислены с помощью симметричного фильтра сглаживания скользящей средней продолжительностью 96 часов.




Рисунок s6: Результаты начального обучающего эксперимента [с 6-й по 10-ю неделю] для лучшего набора гиперпараметров. Жирные линии вычислены с помощью симметричного фильтра сглаживания скользящей средней продолжительностью 96 часов.

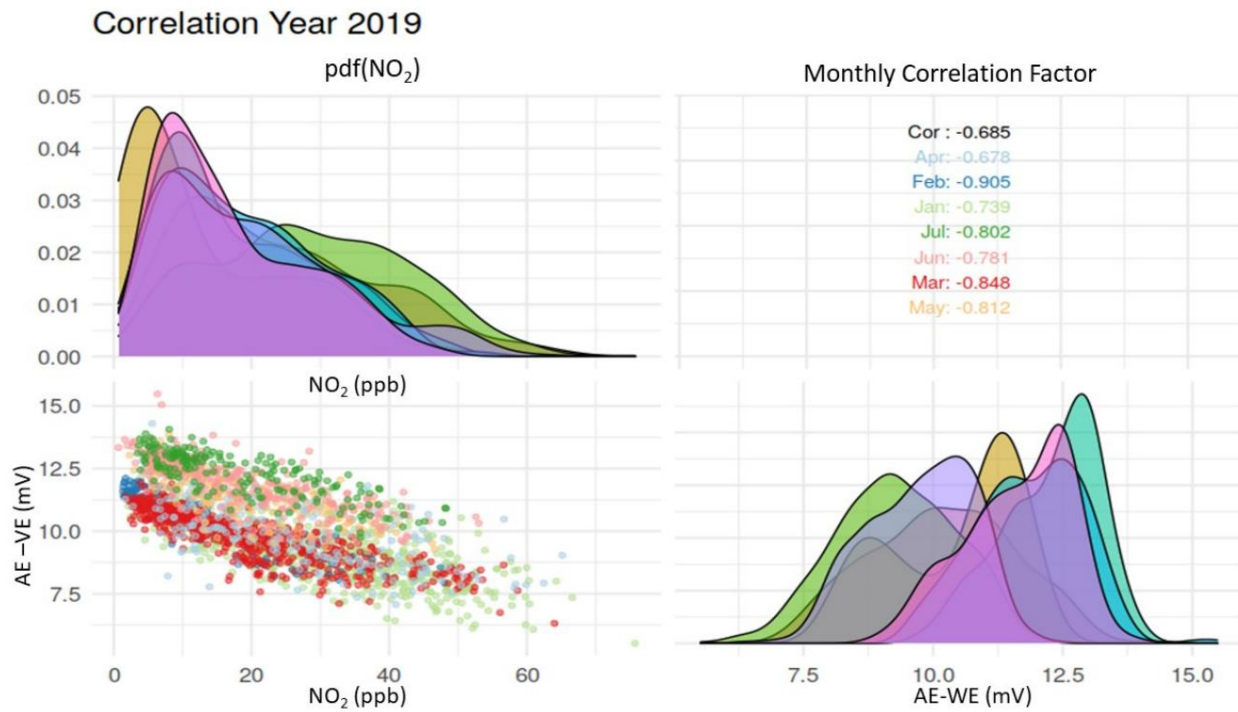


Рисунок s7: Коэффициенты корреляции Пирсона между заданной концентрацией газа NO_2 и необработанными показаниями датчика NO_2 (разница AE-WE), рассчитанные для каждого месяца в 2019 г. (правый верхний угол), ежемесячная эмпирическая pdf (верхний левый угол для NO_2 и нижний правый угол для AE-WE) и точечная диаграмма среди вышеуказанных переменных (нижний левый угол). Разные цвета связаны с разными месяцами. Очевидны значительные сезонные отклонения и изменения чувствительности.