



Списки содержания доступны на сайте ScienceDirect

Датчики и приводы В: Химические

домашняя страница журнала: www.elsevier.com/locate/snbМониторинг загрязнения CO, NO₂ и NO_x в городах с помощью калиброванного на месте электронного носа с автоматической байесовской регуляризацией

Саверио Де Вито*, Марко Пига б, Лука Мартинотто б, Джироламо Ди Франчаа

а ENEA, Centro Ricerche Portici, 80055 Portici (NA), Италия б Pirelli Labs, Viale Sarca 222, 20126 Милан, Италия

информация о статье

История статьи:

Поступила в редакцию 29 апреля 2009 г.

Поступила в редакцию 6 июля 2009 г.

Принят 22 августа 2009 г.

Доступно в Интернете 29 августа 2009 г.

Ключевые слова:

Мониторинг загрязнения воздуха в городах

Калибровка в полевых условиях

Электронный нос

Мультисенсорное устройство

Выбор функций

Электронный дизайн носа

Искусственные нейронные сети

Автоматическая байесовская регуляризация

Абстрактные

Недорогие газовые мультисенсорные устройства могут представлять собой эффективное решение для уплотнения разреженной сети мониторинга загрязнения воздуха в городах. В предыдущей работе мы предложили и оценили калибровку такого устройства с использованием краткосрочных данных, записанных в полевых условиях, для количественной оценки загрязнения бензолом. В этой работе мы представляем и обсуждаем результаты, полученные для оценки концентрации загрязняющих веществ CO, NO₂ и общего NO_x на той же установке. Для предоставления справочных данных используется обычная станция мониторинга загрязнения воздуха. Мы показываем, как можно выполнить многомерную калибровку с использованием двухнедельной записи полевых данных и систем нейронной регрессии. Также для этих загрязняющих веществ не было обнаружено значительного повышения производительности при использовании более длинных записей. Также обсуждается влияние правильного выбора характеристик на достижение оптимальных характеристик при сравнении долгосрочных результатов полученных калибровок. Преимущества и проблемы калибровки на основе многомерной корреляции оцениваются в ходе одногодичной измерительной кампании.

© 2009 Elsevier BV Все права защищены.

1. Введение

Мониторинг загрязнения городов в настоящее время осуществляется сетью станций на базе промышленных спектрометров. Их размеры и стоимость делают нереальной реализацию измерительной сетки с соответствующей плотностью.

Динамика распространения загрязнения внутри городов действительно очень сложна из-за сложной структуры дорог и зданий. В действительности типичная детализация сетки мониторинга превышает несколько километров, что может ухудшить репрезентативность собираемых данных относительно фактического распределения концентраций загрязняющих веществ на городских территориях. Например, дороги, окруженные высокими зданиями, могут подвергаться очень высокому уровню загрязнения из-за так называемого эффекта концентрации каньона, даже если близлежащая станция мониторинга сообщает о чрезвычайно низком уровне загрязнения [1–3]. С другой стороны, знание фактической картины концентрации загрязнения в городских районах в режиме реального времени считается критически важным для реализации продуманной политики управления дорожным движением и управления загрязнением воздуха [4].

В последние годы некоторые авторы предлагают использовать газовые мультисенсорные устройства в качестве инструмента для сгущения сетки мониторинга городского загрязнения из-за значительно низкой стоимости единицы

Их уменьшенное размерное воздействие делает их подходящими даже для исторических центров городов, где их можно легко спрятать, сохраняя архитектурное наследие.

К сожалению, внутренние проблемы долговременной стабильности и селективности, которые влияют на твердотельные датчики, на которые они полагаются, могут серьезно ограничить их надежность, особенно по сравнению с хорошо зарекомендовавшими себя характеристиками обычных анализаторов. Некоторые исследования подтверждают, что при калибровке для количественного определения одного вида в лаборатории они демонстрируют плохие характеристики при работе в реальных условиях, показывая низкую надежность обычного процесса калибровки в лаборатории при работе со сложными смесями [5,6].

Недавно для преодоления этих проблем были предложены некоторые стратегии калибровки в полевых условиях [6–8]. В частности, наша группа предложила использовать станцию на базе спектрометров в качестве эталона для калибровки в полевых условиях небольшого мультисенсорного устройства, что позволило получить очень обнадеживающие результаты для целей количественного определения бензола. Мы также сосредоточились на оптимальной продолжительности процесса калибровки, обнаружив, что нейронная сеть, обученная с использованием 10-дневного набора измерений, была способна получить относительную ошибку оценки менее 0,02 (2%) в течение более 6 месяцев [8]. . Наблюдалось долговременное ухудшение продуктивности, которое интерпретировалось как вызванное изменением абсолютной и относительной концентрации различных видов в зимнее время. Было обнаружено, что процедура повторной калибровки, выполняемая каждые 6 месяцев, эффективно восстанавливает уровень производительности. Аналогично, Tsujita et al.

Автор корреспонденции. Тел.: +39 0817723364, факс: +39 0817723344.

Адрес электронной почты: saverio.devito@portici.enea.it (С. Де Вито).

схема повторной калибровки, которая может быть полезна, по крайней мере, для решения проблем со стабильностью сенсора [9].

Алгоритмы распознавания образов часто используются в качестве инструментов автоматизированного многомерного анализа при обнаружении газов, но их эффективность редко обсуждается, особенно для задач регрессии, например задач количественной оценки концентрации [10–11]. В этих задачах подсистемы слияния датчиков разрабатываются для аппроксимации в:

$$C_j = (RSens1, RSens2, \dots, RSensn)$$

где C_j — реальная j -я концентрация загрязнителя, измеренная обычными станциями, а $RSens_i$ — сопротивление i -го датчика, измеренное мультисенсорным устройством.

В сложном сценарии, таком как мониторинг городского загрязнения, глубокий анализ результатов, полученных такой системой, может значительно помочь в оценке осуществимости, направляя разработку соответствующих стратегий мониторинга (расположение устройств, методология калибровки и долгосрочная оценка производительности), а также процесс проектирования и проверки приборов.

В этой статье мы изучаем оценку производительности мультисенсорного устройства, откалиброванного в полевых условиях, представляя результаты, полученные для оценки концентрации CO, NOx и NO2. Мы анализируем результаты, пытаясь получить глубокие знания об основных факторах производительности в выбранном сценарии, подтверждая гипотезу с помощью корреляционного анализа, выбора функций и долгосрочной производительности. оценка.

2. Экспериментальная установка

Мультисенсорное устройство, разработанное Pirelli Labs (см. [12]), было совмещено с обычным анализатором загрязнения воздуха, находящимся в ведении регионального агентства по охране окружающей среды (ARPA). Стандартный отклик анализатора использовался для получения истинных значений концентрации целевых загрязняющих веществ в месте измерения. Таким образом, эти значения использовались в качестве эталона для настройки системы многомерной регрессии, предназначенной для калибровки отклика мультисенсорного устройства. Это мультисенсорное устройство было разработано для размещения пяти нестандартных хеморезистивных датчиков на основе оксидов металлов, а также двух коммерческих твердотельных датчиков относительной влажности и температуры. Он имеет очень компактную конструкцию (объем = $9,7 \times 10^{-3}$ м³) и легко разворачивается в оперативном сценарии из-за ограниченного веса (менее 2,5 кг). Встроенный микроконтроллер обеспечивал вычислительную платформу, контролирующую аналого-цифровое преобразование, а встроенное вторичное запоминающее устройство обеспечивало локальную емкость хранения до 72 часов измерений данных с периодом выборки 8 с. Среднечасовое значение измерений передавалось через модем GPRS на приемники данных класса ПК. Более подробное описание приборов и установок можно найти в [8].

Обычная стационарная станция обеспечивала эталонную оценку концентрации CO (мг/м³), метановых углеводородов (NMHC) (г/м³), C6H6 (г/м³), NOx (млрд.), NO2 (г/м³). Отбирали образцы, записывая среднечасовые значения концентрации. К сожалению, всего через 8 дней анализатор NMHC вышел из строя.

Пробы мультисенсорного устройства были отобраны для получения среднечасового значения удельного сопротивления, выраженного химическими резисторами на основе CO, NOx, O3 и NO2, специфичными для оксидов металлов (MOX), датчиком МОКС, ориентированным на NMHC, характеристики которого также подробно описаны в [8], а также коммерческая температура. и датчики относительной влажности. Измерительная кампания проводилась на одной из главных улиц в центре итальянского города с интенсивным автомобильным движением. Кампания по сбору данных продолжалась с марта 2004 г. по апрель 2005 г., в результате чего был создан годичный набор данных для разработанного приложения.

3. Экспериментальный сценарий и обсуждение методов

По результатам нашего предыдущего исследования полигон характеризовался наличием значимых корреляций между временными рядами зарегистрированных концентраций видов [8]. Для создания нелинейной многомерной калибровки мультисенсорного устройства была разработана архитектура нейронной сети с обратным распространением для решения типичной задачи регрессии. Система была фактически обучена оценивать реальные среднечасовые концентрации загрязняющих веществ, полученные обычным анализатором, с использованием среднечасовых значений электрического сопротивления, выраженных химическими резисторами мультисенсорного устройства, используемыми в качестве входных характеристик.

В рамках статистического распознавания образов задачи полной регрессии характеризуются необходимостью аппроксимации «апостериорного» распределения целевых случайных величин при заданных значениях измеряемых переменных (см. [10]). На практике типичная система статистической регрессии работает путем аппроксимации функциональных взаимосвязей (если они существуют) между измерениями в «пространстве признаков» и ожидаемыми выходными значениями, начиная с предопределенной внутренней модели и используя ограниченный набор данных (обучающий набор) в качестве примеров для настроить его. Если выбор обучающего набора репрезентативен для реального статистического распределения данных, мы можем ожидать, что обученный регрессор сможет правильно оценить искомые функциональные отношения, сохраняя соответствующие свойства обобщения. Конечно, шум как в измерении, так и в целевых переменных будет влиять на общую производительность оценки в различной степени.

В нашем сценарии оценки концентрации загрязняющих веществ мы можем ожидать достаточно хороших характеристик, если пул датчиков, фактически составляющих пространство признаков, включает блок датчиков, демонстрирующий хорошие свойства селективности и стабильности для каждого целевого загрязнителя. В этом случае одномерная калибровка может представлять собой жизнеспособное решение. Обычно это очень трудно получить из-за внутренних свойств и ограничений твердотельных датчиков.

Можно ожидать хороших уровней производительности, даже если датчик, специфичный для цели, подвержен значительным проблемам с селективностью, но в этом случае правильно разработанный пул датчиков может быть способен описать влияние помех на отклик датчика, специфичного для цели. Это может, например, произойти, если реакция подгруппы сенсоров сильно коррелирует с концентрациями мешающих веществ. В этом случае статистический регрессор мог бы извлечь достаточно информации о концентрациях мешающих веществ и их влиянии на отклики других датчиков газа, чтобы смоделировать такие влияния на этапе обучения и обеспечить подавление индуцированных ошибок. Например, если на оценки концентрации CO влияет присутствие определенного мешающего вещества, скажем, H2S, подсистема объединения датчиков может научиться оценивать и вычитать влияние на целевой датчик CO, если вы можете измерять концентрации H2S и у вас есть репрезентативный набор обучающих выборок для ее моделирования.

В нашем сценарии обычное наличие значительной корреляции между концентрациями загрязняющих веществ также может помочь статистическому регрессору извлечь информацию о концентрации конкретного газа, даже если соответствующие характеристики датчика низки или, в конечном счете, если в измерении нет конкретного целевого датчика. сенсорный пул. В этом случае концентрация целевого газа оценивается исходя из отклика датчиков на газы, концентрации которых сильно коррелируют, не обязательно линейно, с концентрацией преследуемого газа. Эта особенность может иметь существенный недостаток из-за возможного изменения относительных концентраций газов на сезонной или пространственной основе, как, например, дифференциальное увеличение концентрации основных загрязняющих веществ (см., например, [3]) и увеличение выбросов NOx при отоплении жилых помещений, как в зимний период, так и в зимнее время. На самом деле, эти изменения могут серьезно снизить значимость знаний, связанных с тренировочным набором.

Последняя работа была посвящена результатам определения концентрации бензола. Мы показали, как в этом случае можно было оценить концентрацию загрязняющего вещества, для которого не

датчик присутствовал в выбранном пуле датчиков, используя информацию, полученную от датчика NMHC. На самом деле бензол наиболее значительная часть загрязнения, связанного с НМУ, в выбранном сценарии. Мы также обнаружили измеримое снижение производительности при использовании а Весеннее время получило калибровку в зимнее время из-за вышеупомянутый эффект, связанный с загрязнением отопления дома.

В этой работе мы показываем результаты, полученные при калибровке нейронных сетей прямого распространения в схеме регрессии для NO_x, NO₂ и CO₂ концентрации загрязняющих веществ в том же прикладном сценарии, чтобы проверить обобщение результатов, связанных с бензолом. Расследования отношения производительности к продолжительности обучения были проводится для сравнения результатов с полученными для бензола. Влияние выбора признаков и корреляции на основе обучения были исследованы и оценены.

Используя обычные выходные данные станции, нейронные сети были обучение и моделирование в среде Matlab; гиперболический тангенс был выбран в качестве скрытой передаточной функции нейрона. Для обучения был выбран алгоритм Левенберга-Марквардта. эксперименты, ранняя остановка и автоматическая байесовская регуляризация (ABR) использовались в качестве алгоритмов контроля сложности для избежать проблем с чрезмерным обучением [13,14]. Тренировочные наборы были построены с использованием последовательных выборок, т. е. с использованием определенного интервала данных кампании фиксированной длины, в то время как валидация (при использовании для ранней остановки) была строится путем случайного выбора выборок из оставшихся данных. Два подходы были разработаны для оценки неопределенности производительности и для целей обобщения, один из которых основан на перекрестная проверка.

Автоматическая байесовская регуляризация — это пропускная способность нейронной сети. методика управления обучением нейронных сетей; это было введено в конце 90-х годов, но его использование до сих пор редкость в электронной носовое сообщество. Обучение внутренней модели регрессора обычно предполагает минимизацию функции ошибки. В традиционных нейронных сетях для обучения обратному распространению функция ошибки в основном учитывать только эмпирическую ошибку (т. е. ошибку на обучающем наборе), а емкость модели (т. е. количество скрытых нейронов) фиксировано, и сложность решения должна тщательно контролироваться. Эта процедура, ориентированная на данные обучения, может легко привести к избыточной подгонке данных. Подходы, основанные на теории регуляризации (см. [10] для подробное описание) попытаться сбалансировать эмпирическую ошибку с термин, связанный со сложностью модели, их глобальная функция ошибок описано:

$$\sum_{n=1}^N \frac{1}{2} (w_1 x_n + w_2)^2 \quad (2)$$

где n — индекс бегущей обучающей выборки, эмпирический N — функция ошибок, вычисленная на n -й из k полных обучающих выборок w_1, w_2 — параметры регуляризации. В нейронных сетях, w учитывать значения весов сети, пытаюсь оценить сложность сетевой модели по их норме. Неприличный условиях, стремление к минимизации (2) приводит к минимизации таких избыточных весовых значений связи, которые могли бы производят перетренированность. Обычно это также позволяет более плавно ответ сети, и эффект аналогичен тому, что можно получить за счет обрезки лишних сетевых подключений. На самом деле, что касается как сетевая архитектура, путем регуляризации, любой скромной сеть большого размера должна быть в состоянии аппроксимировать функцию регрессии, сохраняя хорошие свойства обобщения.

Чтобы избежать как недообучения, так и перетренированности, w_1, w_2 значение должно быть, конечно, тщательно настроено, и это добавляет свободные параметры, которые необходимо оптимизировать.

ABR — это методология обучения, основанная на регуляризации, которая пытается оценку w_1, w_2 в байесовской системе (см. [10,15]), начиная исходной гипотезы о статистическом распределении весов, а одновременно минимизируя (2) с помощью Левенберга-Марквардта алгоритм обучения сети. В байесовской системе весов

рассматриваются как случайные величины, так как их апостериорная вероятность плотность можно описать как:

$$P(w|D, \tilde{w}, M) = \frac{P(D|w, \tilde{w}, M)P(w|\tilde{w}, M)}{P(D|\tilde{w}, M)} \quad (3)$$

D — собранный набор данных, M — конкретная нейронная сеть. модель.

Предполагая гауссово распределение для априорного распределения весов сети и шума обучающей выборки, оптимальная максимизация весов (3) также минимизировать регуляризованную функцию ошибок, заданную в (2). В ABR, каждый шаг обучения сети добавляет знания о распределении весов, практически получая аппроксимацию, скажем, w значений wMP , которые максимизируют апостериорную вероятность в (3). Это знание может быть использовано для обновления неоптимальных значений w_1 и w_2 в соответствии с максимизация

$$P(w_1, w_2|D, \tilde{w}, M) = \frac{P(D|w_1, w_2, \tilde{w}, M)P(w_1, w_2|\tilde{w}, M)}{P(D|\tilde{w}, M)} \quad (4)$$

На самом деле, добавляя вероятное предположение о равномерности $P(w_1, w_2|\tilde{w}, M)$

затем, после простых аналитических шагов, аппроксимации wMP и w_1MP можно найти с помощью (3):

$$\text{знак равно} = \frac{K}{2N} \cdot \frac{1}{2} \quad \text{, знак равно} = \frac{K}{2} \cdot \frac{1}{n(w)} \quad (5)$$

с так называемым числом эффективных параметров, т.е. мера количества параметров нейронной сети, которые эффективно использовать функцию минимизации ошибок. Значение вычисляется как

$$= N - 2 \cdot \text{tr}(H)^{-1} \quad (6)$$

используя матрицу Гессе H целевой функции, Приближение Гаусса – Ньютона легко доступно с использованием Алгоритм обучения Левенберга-Марквардта.

Полученная аппроксимация wMP и w_1MP , в свою очередь, изменяет уравнение (2) и, следовательно, наилучшие значения w , которые можно получить с помощью дальнейшей итерации обучения. Процесс повторяется до сходимости. Обратите внимание, что, после инициализации сетевых весов w_1 и w_2 инициализируются в 0 и 1, соответственно, перед выполнением первого шага обучения алгоритм.

4. Результаты и обсуждение

Первоначально, чтобы позволить читателю сравнить уровень ошибок для CO, NO_x и NO₂ с выводами, связанными с бензолом, о которых сообщалось в В нашей предыдущей работе был проведен предварительный регрессионный эксперимент. настраивать. Двухнедельный сегмент данных, начиная с первого день измерений и использования всех откликов датчиков, был используется как тренировочный набор. Только в этом предварительном эксперименте проверочная выборка, состоящая из 40% оставшихся выборок, была случайным образом выбрана. извлечены и зарезервированы для осуществления ранней остановки стратегия. Остальные образцы использовались в качестве тестового набора для проверки производительности. оценка. Были разработаны три разные сети, каждая из которых была нацелена на решение конкретной задачи по оценке концентрации аналита. Алгоритм Левенберга-Марквардта, используемый в учебных целях. число скрытых слоев было эмпирически установлено равным 25 для всех трех при этом оценка результатов повторялась 20 раз и усреднялась с целью уменьшения локальных минимумов и исходного выбора веса. влияет. Средняя относительная ошибка (MRE), рассчитанная как

$$MP\bar{E} = \frac{1}{N} \sum_{i=1}^N \frac{|y_i - x_i|}{y_i} \quad (7)$$

где y_i — истинное значение концентрации в i -й пробе, принадлежащей к тестовому набору, x_i оценка концентрации сети и N количество задействованных тестовых образцов было установлено как первичная производительность

как для этого, так и для последующих экспериментов.

Мы нашли $MRE(NO_2) = 0,26$, $MRE(NO_x) = 0,42$ и $MRE(CO) = 0,32$. Хотя показатели MRE значительно хуже, чем рассчитанные для бензола с аналогичными настройками ($MRE = 0,02$), даже в этом случае отношение между средней абсолютной ошибкой (MAE), рассчитанное как

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \quad (8)$$

годовой диапазон концентраций для одного вида был обнадеживающим: 3 % для CO, 8 % для NO₂ и 7 % для NO_x. Для сравнения, единицами измерения их концентраций были, соответственно, мг/м³, г/м³, ppb. Наиболее существенное негативное влияние на относительную ошибку было обнаружено при низких уровнях концентрации, обычно достигаемых в ночное время.

Также интересно отметить, что для всех этих трех видов показатели, полученные на нормализованном обучающем наборе с точки зрения среднеквадратичной ошибки (MSE), как правило, на три порядка выше, чем показатели, полученные для бензола в той же установке. Этот результат объясняется значительным «зашумленным» поведением переменных пространства признаков (сопротивлений датчиков) в ответ на эти концентрации частиц, что подтверждает заведомо худшую описательную способность сенсорной матрицы в условиях эксплуатации по отношению к этим концентрациям частиц.

Следует подчеркнуть, что использование ранней остановки делает вышеуказанные результаты зависящими от слияния знаний, связанных с обучающим и проверочным набором, а не только от данных обучающего набора. Однако аналогичные, но более строгие результаты в отношении влияния длины тренировочного набора на производительность были получены без использования какого-либо набора для проверки и представлены в следующих параграфах, которые представляют собой основу этой статьи, создавая основу для сделанных выводов. .

4.1. Оценка оптимальной продолжительности обучения

В качестве второго исследования мы хотели проверить оптимальную продолжительность обучения при использовании последовательных выборок. В случае бензола 10-дневная обучающая выборка оказалась способной восстановить ожидаемый суточный и недельный цикл изменения статистического распределения концентрации загрязнителя. Наша гипотеза заключалась в том, что результаты, полученные для бензола, можно было бы обобщить и для других соединений.

По этой причине мы настроили процедуру оценки обучения, используя отклик всей матрицы датчиков и различные длины обучающего набора для CO и NO₂. Обучение сетей проводилось с использованием алгоритма Левенберга–Марквардта с автоматической байесовской регуляризацией для контроля сложности, поэтому без использования какого-либо проверочного набора. Номер скрытого слоя изначально был установлен равным 5 на основе предварительных результатов.

В качестве первого эксперимента мы создали обучающий набор последовательных выборок разной длины, начиная с первой выборки доступного набора данных (1 марта). Для каждой выбранной длины обучения все оставшиеся образцы использовались в качестве тестового набора. Фактически, каждая продолжительность обучения давала разные регрессоры с разными характеристиками, которые мы хотели сравнить, используя наборы тестов разной длины. В аналогичной установке важно оценить неопределенности в оценке производительности, чтобы понять значимость сообщаемых различий, возможно, для достижения обобщения результатов. Основным источником неопределенностей в оценке производительности, с которым следует бороться, является использование ограниченного набора тестов различной продолжительности. Также хорошо известно, что результат процесса обучения самой нейронной сети подвержен неопределенности из-за начального выбора весов и связанных с этим проблем с локальными минимумами.

Итак, для каждой обученной сети, характеризующей своей парой наборов (обучающей, тестовой), вычислялись наблюдения ошибок оценивания концентрации на тестовом наборе. Для каждой длины обучения процедура повторялась 20 раз, чтобы уменьшить влияние выбора начальных весов HC, однако вариативность на производительность

показатели были незначительными, за исключением случая оценки концентрации CO для продолжительности обучения 96 часов, для которого результаты теста были нестабильными.

Что касается оценки неопределенности, наблюдение за ошибками оказалось не точным; на самом деле они показали значительную автокорреляцию. На самом деле их автокорреляционная функция (АКФ) оказалась определенно не импульсивной, а абсолютная ошибка АКФ лишь медленно затухала под доверительными интервалами белого шума для АКФ. По этой причине доверительные интервалы среднего значения выборки не могли быть рассчитаны с использованием CLT и t-статистики только потому, что наблюдения не соответствовали требованию iid (независимые и одинаково распределенные). Чтобы правильно вычислить доверительные интервалы для MRE и MAE, был использован новый алгоритм, предложенный Zhang в [16] для расчета неопределенности выборочного среднего автокоррелированных измерений. Эта методология основана на слабой гипотезе стационарности, которая позволяет моделировать авторегрессионное скользящее среднее для процесса измерения.

Интересно отметить, что рассчитанные таким образом доверительные интервалы заметно шире, чем классические, как и можно было ожидать, учитывая меньшее количество наблюдений независимых переменных во временных рядах, связанных с автокоррекцией. Следует также отметить, что наблюдения абсолютных ошибок показывают заметную тенденцию во времени, в этой ситуации автор предупреждает, что использование самого усредненного значения MAE и соответствующей дисперсии для характеристики регрессионных систем может ввести в заблуждение. По этой причине, хотя они и приводят к одним и тем же выводам, мы основывали наши сравнения на расчетных значениях MRE как на первичном показателе эффективности. Результаты для CO и NO₂ представлены в [таблицах 1 и 2](#) соответственно. Они показывают, что для этого года не может быть достигнуто особых преимуществ за счет увеличения продолжительности обучающей выборки, начиная с первой доступной выборки, более чем на две недели при оценке концентраций загрязняющих веществ по оставшимся выборкам этого года.

Еще один эксперимент был проведен для сравнения, т. е. для сравнения длительности нескольких обучающих наборов в несколько иной настройке. На этот раз мы использовали постоянную продолжительность набора тестов и фиксированное местоположение набора тестов во временном ряду набора данных. Все регрессоры тестировались на одном и том же тестовом наборе, т.е. в течение последних 6 месяцев кампании. Время начала обучающих наборов, процедуры обучения и архитектура регрессоров были такими же, как и в предыдущем эксперименте. Хотя эта установка может быть правильно воспринята как штрафная для коротких обучающих наборов, все образцы которых расположены задолго до начала тестового набора, результаты могут представлять собой идеальное сравнение для представленных выше. Результаты, представленные в [Таблице 3](#) , показывают существенное подтверждение того, что уже найдено.

Локализация обучения и тестирования в определенное время в описанной выше установке может поставить под сомнение возможность обобщения результатов. Конечно, то же самое относится и к процессу выбора обучающей выборки. По этой причине, чтобы сравнить и обобщить показатели производительности, полученные в результате использования различных вариантов длины обучающего набора, мы решили применить особый подход к перекрестной проверке, который мог бы учитывать обучающие (и тестовые выборки), расположенные в разных временных точках. Зададим следующую процедуру перекрестной проверки: за весь год кампании, учитывая фиксированную длину тестовой выборки h , соответствующую 6 месяцам, и для каждой выбранной длительности обучающей выборки i , тогда k взаимноисключающих последовательных обучающих выборок T_i индекс обучающей выборки имеют было рассмотрено, с

$$\text{Общая длина БД} \text{ --- } h_k = i \quad (9)$$

На самом деле, для каждого выбора тренировочного набора T_i , из i последовательных образцов, h следующих друг за другом последовательных образцов рассматривались как его специфический тестовый набор T_{i+h} . MRE, стандартная ошибка и относительная ошибка (STD MRE) были вычислены для каждого T_i и T_{i+h} . Также были вычислены STD MRE и квадратичный коэффициент корреляции (SCC), вычисленные для каждого T_{i+h} , использовались в качестве показателей.

Таблица 1

Показатели оценки концентрации CO схемы нейронной регрессии, рассчитанные для разных длин обучающего набора. Все ответы датчиков были использованы для функции векторной композиции, в скрытом слое использовались пять нейронов, для контроля сложности использовался ABR. Для каждого выбора обучающей выборки оставшиеся выборки набор данных использовался в качестве тестового набора. Значения МАЭ выражены в мг/м3. Приведены доверительные интервалы для MRE и MAE. Только небольшие улучшения производительности измеримо при использовании записи данных более двух недель.

Часы	MRE	ки	СТД РЕ	МАЭ (мг/м3)	КИ (мг/м3)	Стандартная ПДК (мг/м3)	CCC
24	0,49	±0,13	1,08	0,58	±0,10	0,43	0,77
96	0,78	±0,37	1,37	1,56	±0,31	1,19	0,18
240	0,34	±0,09	0,86	0,53	±0,16	0,63	0,79
360	0,32	±0,07	0,84	0,51	±0,10	0,51	0,82
600	0,31	±0,09	0,85	0,44	±0,13	0,46	0,86
1200	0,32	±0,13	0,98	0,41	±0,10	0,42	0,85
1800	0,31	±0,13	0,99	0,41	±0,10	0,42	0,84
2400	0,29	±0,11	0,74	0,46	±0,11	0,49	0,87

Таблица 2

Показатели оценки концентрации NO2 схемы нейронной регрессии, рассчитанные для различных длин обучающего набора. Все ответы датчиков были использованы для функции векторной композиции, в скрытом слое использовались пять нейронов, для контроля сложности использовался ABR. Значения MAE выражены в г/м3. Доверительные интервалы сообщаются для MRE и MAE. Для NO2 наблюдается небольшое ухудшение результатов при увеличении тренировочного набора на десять дней.

Часы	MRE	ки	СТД РЕ	МАЭ (г/м3)	КИ (г/м3)	STD AE (г/м3)	CCC
24	0,60	±0,23	1,04	49,4	±9,53	35,0	0,09
96	0,31	±0,10	0,68	30,2	±10,1	25,4	0,36
240	0,22	±0,07	0,62	23,7	±7,10	21,0	0,66
360	0,21	±0,07	0,63	19,8	±5,32	18,3	0,71
600	0,23	±0,07	0,66	27,1	±8,70	25,9	0,62
1200	0,27	±0,07	0,65	26,5	±9,70	23,1	0,58
1800	0,26	±0,07	0,61	27,7	±10,0	24,6	0,59
2400	0,27	±0,10	0,68	28,2	±7,90	23,2	0,54

Таблица 3

Показатели оценки концентрации CO схемы нейронной регрессии, рассчитанные для различных длин обучающего набора. Все ответы датчиков были использованы для функции векторной композиции, пять нейронов использовались в скрытом слое, ABR использовался для контроля сложности. За последние 6 месяцев всего набора данных кампании было используется в качестве тестового набора для всех различных регрессоров. Значения МАЭ выражены в мг/м3. Приведены доверительные интервалы для MRE и MAE. Опять же, только небольшая производительность улучшения достигается при использовании более чем двухнедельной записи данных.

Часы	MRE	ки	СТД РЕ	МАЭ (мг/м3)	КИ (мг/м3)	Стандартная ПДК (мг/м3)	CCC
24	0,49	±0,13	1,08	0,58	±0,10	0,43	0,77
96	0,87	±0,25	1,57	1,28	±0,17	1,11	0,11
240	0,36	±0,12	1,02	0,58	±0,07	0,67	0,77
360	0,38	±0,13	1,13	0,58	±0,07	0,68	0,74
600	0,35	±0,10	0,92	0,49	±0,10	0,50	0,82
1200	0,36	±0,16	1,15	0,43	±0,16	0,45	0,84
2400	0,35	±0,15	1,04	0,45	±0,10	0,47	0,84

мансовые индексы. Даже в этом случае и для каждой пары результаты изменчивость, связанная с обучением НС, оказалась незначительной, что подтверждает положительное влияние АБР. Тогда для каждого i будет получено k результатов из разных три m_i, Tex_M пары считались iid наблюдения за показателями производительности и, наконец, были усреднены и их относительная неопределенность рассчитана таким образом, чтобы правильно сравнивать результаты исходя из разных i независимых регрессоров.

В этом случае мы оцениваем возможности оценки различных регрессоров, каждый из которых обучен на обучающем наборе разной длины. тестируется на фиксированном числе тестовых образцов сразу после тренировочный набор.

Полученные результаты для CO и NO2 представлены в [таблицах 4 и 5](#). соответственно. На [рис. 1](#) графически изображено поведение МАЭ вместе с доверительными интервалами при изменении длины тренировки по CO задача оценки концентрации.

Отдельные показатели производительности были значительно хуже, чем у который был найден для случая бензола, для которого наилучший MRE оказался равным 0,02. Однако даже для этих двух видов относительно короткий тренировочный набор, по-видимому, способен произвести результаты, которые очень близки к тому, что можно получить с гораздо более длинными данными устанавливает, существенно ли они отличаются от доступных при наименьшей длине тренировочного набора. Используя более длительную тренировку, установите наблюдается медленный положительный тренд, но неопределенность быстро растет после Длина 700 образцов, для которых мы больше не можем надежно различать среднюю производительность по ошибкам. На самом деле, считайте

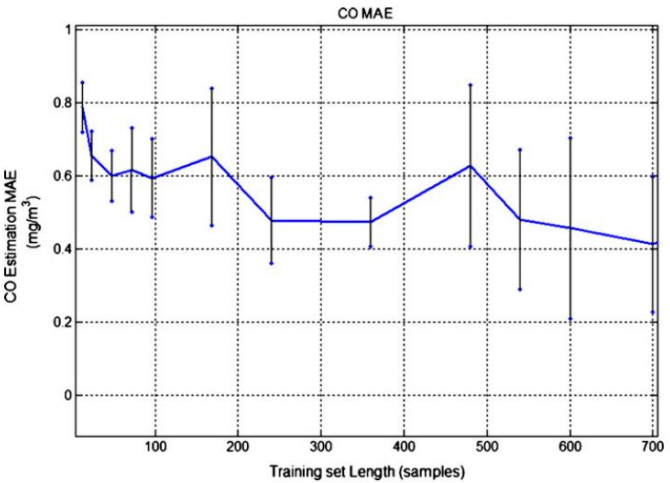


Рис. 1. Оценка концентрации CO MAE, выраженная в мг/м3, по сравнению с обучающей выборкой длина измеряется в выборках (часах) с соответствующими доверительными интервалами. Все датчики ответы были использованы в качестве вектора признаков (настройка перекрестной проверки, см. [Таблицу 4](#) для Детали).

Таблица 4

Показатели оценки концентрации CO схемы нейронной регрессии, рассчитанные для различных длин обучающего набора (тестовый набор фиксированной длины, настройка перекрестной проверки). Все ответы датчиков использовались для составления вектора признаков, пять нейронов использовались в скрытом слое, ABR использовался для контроля сложности. Уверенность интервалы указаны для MRE, MAE и SCC. Результаты теста Уэлча показывают, что нельзя добиться значительного повышения производительности за счет увеличения длины тренировочного набора. более двух недель.

Часы	MRE	КИ	СТД РЕ	МАЭ (мг/м3)	КИ (мг/м3)	Стандартная ПДК (мг/м3)	CCC	КИ
12	0,55	±0,06	1,02	0,79	±0,07	0,67	0,76	±0,01
24	0,46	±0,05	0,94	0,66	±0,07	0,58	0,80	±0,01
48	0,42	±0,05	0,84	0,60	±0,07	0,54	0,82	±0,02
72	0,42	±0,07	0,82	0,61	±0,11	0,55	0,82	±0,02
96	0,39	±0,06	0,75	0,59	±0,11	0,53	0,82	±0,03
168	0,42	±0,11	0,80	0,65	±0,19	0,59	0,78	±0,08
240	0,34	±0,09	0,76	0,48	±0,11	0,49	0,84	±0,03
360	0,32	±0,08	0,76	0,45	±0,07	0,47	0,84	±0,03
480	0,38	±0,10	0,68	0,63	±0,22	0,62	0,78	±0,09
540	0,32	±0,14	0,71	0,48	±0,19	0,52	0,84	±0,02
600	0,30	±0,12	0,65	0,46	±0,24	0,45	0,85	±0,03
700	0,30	±0,18	0,76	0,41	±0,18	0,43	0,84	±0,13
800	0,34	±0,25	0,62	0,51	±0,44	0,48	0,84	±0,09
900	0,29	±0,18	0,80	0,40	±0,29	0,46	0,86	±0,12
1200	0,29	±0,24	0,75	0,40	±0,58	0,42	0,87	±0,03

Таблица 5

Показатели оценки концентрации NO2 схемы нейронной регрессии, рассчитанные для различной длины обучающего набора (тестовый набор фиксированной длины, настройка перекрестной проверки). Все ответы датчиков использовались для составления вектора признаков, пять нейронов предполагались в скрытом слое, ABR использовался для контроля сложности. Уверенность интервалы указаны для MRE, MAE и SCC. Результаты теста Уэлча показывают, что нельзя добиться значительного повышения производительности за счет увеличения длины тренировочного набора. более двух недель.

Часы	MRE	КИ	СТД РЕ	МАЭ (г/м3)	КИ (г/м3)	STD AE (г/м3)	CCC	КИ
12	0,46	±0,03	0,91	41,2	±3,22	30,8	0,48	±0,02
24	0,46	±0,04	0,91	42,7	±4,98	32,6	0,53	±0,02
48	0,44	±0,06	0,90	40,7	±6,81	32,8	0,54	±0,03
72	0,39	±0,04	0,78	36,9	±4,79	33,4	0,47	±0,05
96	0,40	±0,05	0,72	39,8	±7,89	34,35	0,51	±0,05
168	0,37	±0,06	0,75	36,1	±8,52	32,37	0,48	±0,09
240	0,34	±0,08	0,76	34,6	±11,1	33,8	0,48	±0,11
360	0,32	±0,13	0,73	32,6	±18,1	31,83	0,57	±0,12
480	0,31	±0,13	0,72	31,9	±16,7	34,9	0,51	±0,18
540	0,34	±0,32	0,72	36,5	±41,3	36,2	0,56	±0,17
600	0,28	±0,16	0,70	29,5	±26,0	30,0	0,48	±0,49
700	0,33	±0,35	0,70	33,9	±52,1	30,2	0,46	±0,66
800	0,28	±0,14	0,68	29,5	±20,7	27,4	0,49	±0,40
900	0,34	±0,61	0,74	37,6	±136	44,5	0,27	±3,28
1200	0,30	±0,81	0,68	30,4	±120	25,7	0,49	±2,44




Рис. 2. Почасовая оценка концентрации NO2, выраженная в г/м3, за одну неделю период. Синяя пунктирная линия представляет истинное значение концентрации, сообщаемое обычным анализатором. (Для интерпретации ссылок на цвет в легенде к этому рисунку см. читатель отсылается к веб-версии статьи.)

Наблюдения за показателями производительности как нормально распределенные (критерий Колмогорова–Смирнова), двухвыборочный правосторонний критерий Велча1, тестирование против гипотезы H0 об отсутствии существенной разницы в среднее значение, проведенное для наблюдений MAE в CO с длинами тестовых наборов из 96 и 360 образцов дал ар = 0,02, что привело к отбраковке

1 Настройки, подобные Беренсу-Фишеру, с использованием приближения Саттертуэйта для при , = 0,05.

H0. И наоборот, нулевая гипотеза не может быть отвергнута ни при каких настройках. использование тестового набора длины 360 вместе с более длинными тренировочными наборами, связанными полученные результаты. Аналогичное поведение обнаружено для оценок MRE, например, с использованием длина теста, равная 72 и 360, дала ар = 0,04. Похожий были проведены испытания и для NO2 , что привело к существенному подтверждение.

Общие результаты подтверждают осуществимость полевого подхода. для калибровки мультисенсорных устройств в сценарии загрязнения воздуха в городе, показывая, как можно провести ограниченную обучающую кампанию. используется для вычисления оптимальной калибровки для нескольких следующих месяцев. Однако абсолютный уровень производительности зависит от описательная мощность выбранного массива датчиков для конкретного задача оценки концентрации загрязняющих веществ.

4.2. Выбор функций

Дальнейшее исследование включало проверку влияния функции процедура выбора по получаемой производительности в нашем сценарии. Выбор признаков может расширить знания экспериментатора. об информационном вкладе одного датчика в задачу оценки концентрации для каждого вида. Этот особенно верно, если отбор проводится с использованием грубой силы подход, т.е. изучение всех доступных комбинаций наборов функций и их производительность, хотя это может быть очень затратным с точки зрения вычислений и, следовательно, это не всегда жизнеспособный выбор.

Таблица 6

Оценка производительности для различных составов векторов признаков в задаче оценки концентрации NO2. Использовалась тренировочная установка продолжительностью десять дней. Доверительные интервалы сообщаются для MRE и MAE.

Набор функций							MRE	MAE (r/m3)
CO	HMFC	NOx	NO2	O3	T			
Икс	Икс	Икс	Икс	Икс	Икс	Икс	0,31 ± 0,07	36 ± 13,0
							0,29 ± 0,09 0,43	29 ± 9,8
							± 0,22 0,47 ±	33 ± 6,7
							0,13 0,29 ± 0,07	50 ± 24,7
							0,29 ± 0,11 0,36	29 ± 8,25
							± 0,10	26 ± 6,41
								38 ± 18,3
							0,37 ± 0,11	34 ± 19,1
							0,29 ± 0,09 0,30	29 ± 10,05
							± 0,08 0,35 ±	32 ± 14,0
Икс X XX	Икс	Икс	Икс	Икс	Икс	Икс	0,09 0,39 ± 0,14	38 ± 16,9
							0,28 ± 0,05 0,26	45 ± 23,2
							± 0,06	25 ± 4,53
								28 ± 6,27
Икс XX	Икс	Икс	Икс	Икс	Икс	Икс	0,28 ± 0,08	27 ± 9,95
							0,23 ± 0,10 0,22	19 ± 4,01
							± 0,07 0,22 ±	19 ± 7,97
							0,08 0,28 ± 0,08	20 ± 4,00
							0,22 ± 0,09 0,22	29 ± 14,62
							± 0,09	20 ± 5,01
								20 ± 4,35

В нашем сценарии мы проанализировали доступные характеристики, с точки зрения MRE и MAE, используя другое подмножество исходного массив датчиков для оценки NO2, CO и NOx с отдельными регрессорами. Длина обучающей выборки была установлена на 10 дней, начиная с первый день кампании, согласно предыдущим экспериментам; в оставшиеся образцы использовались в качестве тестового набора. Доверительный интервал был рассчитан с использованием метода Чжана для оценки неопределенности выборочных средних автокоррелированных рядов данных. Уилкоксонов критерий знакового ранга (непараметрические парные выборки без предположения о нормальности) использовался для оценки значимости наблюдаемые различия в производительности при $\alpha = 0,05$. Чтобы оценить реальная производительность операционной системы, проверка выбора функций и общее тестирование производительности должно выполняться на другом наборе, но наша цель, как упоминалось выше, была другой. т.е. расследование если есть значительный эффект выбора функции в этом конкретном сценарий.

Интересно, что для NO2 наилучшие показатели производительности были полученные с использованием всех ответов датчиков; например, с использованием NOx и NO2 отклики датчиков, датчики CO и NMHC или светодиоды NOx, NO2 и CO до соответственно 0,37, 0,29 и 0,30 МРЭ при использовании всего массив датчиков газа привел к MRE 0,22 (см. [Таблицу 6](#) и [Рис. 2](#)). Уровень производительности, который существенно не отличается, может быть получен путем объединения отклика датчика NO2 с датчиками CO и NMHC




Рис. 3. Почасовая оценка концентрации CO в мг/м3 за одну неделю . период. Синяя пунктирная линия представляет истинное значение концентрации, сообщаемое обычным анализатором. (Для интерпретации ссылок на цвет в легенде к этому рисунку см. читатель отсылается к веб-версии статьи.)

отклик. Эти результаты подтверждают возможность достижения подходящих характеристик, даже когда определенные датчики показывают низкие общую производительность, связав их ответы с информацией исходящие от сенсоров, реакция которых направлена на виды показывая высокие коэффициенты корреляции с анализируемым видом (см. [\[8\]](#)).

[Таблица 6](#) подтверждает влияние температуры и влажности на калибровку отклика сенсора в полевых условиях, в данном случае когда речь идет о датчиках NOx и NO2 . Их сенсорный ответ привело к значительному увеличению производительности в сочетании с отклик одиночного датчика NOx, одиночного датчика NO2 , датчиков NOx + NO2 , датчиков NOx + NO2 + O3 . Улучшения не зафиксировано при соединении отклика датчика RH и T с векторами признаков, содержащими CO, NMHC и NO2.

Результаты, полученные при выборе набора датчиков CO, которые изображены в [таблице 7](#), показали, что нелинейная функция NMHC отклик датчика может значительно следовать за концентрацией CO




Рис. 4. Оценка концентрации CO MAE в зависимости от длины тренировочной выборки, измеренной в выборки (часы) с соответствующими доверительными интервалами, только датчик CO и NMHC были использованы для составления вектора признаков (настройки перекрестной проверки, подробности см. в [таблице 9](#)).

Таблица 7

Оценка производительности для различных составов векторов признаков в задаче оценки концентрации CO. Использовалась тренировочная установка продолжительностью десять дней. Уверенность интервалы указаны для MRE и MAE.

Набор функций		MRE	МАЗ (мг/м3)
CO NMHC NOx NO2 O3 T RH			
исс		0,38 ± 0,05	0,72 ± 0,13
XX		0,27 ± 0,06 XX	0,35 ± 0,10
XX		0,31 ± 0,10 0,34 ± 0,06 0,36 ±	0,43 ± 0,10
	исс	0,13 0,33 ±	0,48 ± 0,06
XX	XX	0,09	0,51 ± 0,16
XX	XXX		0,48 ± 0,14

Таблица 8

Показатели оценки концентрации CO схемы нейронной регрессии, рассчитанные для различной длины обучающей выборки с использованием твердотельного датчика CO и NMHC. ответ как вектор признаков. Для каждой длины обучения, начиная с начала временного ряда данных кампании, оставшиеся выборки набора данных использовались в качестве тестового набора. 5 нейроны использовались в скрытом слое, ABR использовался для контроля сложности. Приведены доверительные интервалы для MRE и MAE. Нет значительной производительности улучшение достигается при использовании более чем двухнедельной записи данных.

Часы MPЭ	STD RE	MAE (мг/м3)	STD MAE	-	CCC
				(мг/м3)	
12	0,27 ± 0,05	0,61	0,39 ± 0,07	0,39	0,87
24	0,27 ± 0,05	0,81	0,38 ± 0,05	0,39	0,85
48	0,39 ± 0,10	1,00	0,48 ± 0,10	0,37	0,83
72	0,37 ± 0,08	0,92	0,43 ± 0,06	0,37	0,88
96	0,37 ± 0,08	0,93	0,43 ± 0,07	0,38	0,87
168	0,27 ± 0,08	0,74	0,37 ± 0,07	0,38	0,87
240	0,27 ± 0,06	0,72	0,34 ± 0,07	0,37	0,88
360	0,27 ± 0,05	0,74	0,37 ± 0,04	0,39	0,85
480	0,30 ± 0,07	0,84	0,41 ± 0,05	0,40	0,86
540	0,30 ± 0,06	0,83	0,39 ± 0,04	0,37	0,87
600	0,30 ± 0,05	0,80	0,37 ± 0,05	0,38	0,87
700	0,28 ± 0,05	0,81	0,38 ± 0,05	0,38	0,86
800	0,29 ± 0,05	0,82	0,36 ± 0,05	0,36	0,87
900	0,29 ± 0,06	0,81	0,36 ± 0,06	0,38	0,87
1200	0,29 ± 0,07	0,82	0,36 ± 0,07	0,38	0,87
1600	0,26 ± 0,09	0,76	0,36 ± 0,12	0,39	0,87
1800	0,26 ± 0,09	0,75	0,35 ± 0,11	0,38	0,87
2000	0,26 ± 0,09	0,74	0,38 ± 0,11	0,40	0,87
2200	0,27 ± 0,10	0,80	0,39 ± 0,12	0,44	0,86
2400	0,27 ± 0,09	0,80	0,40 ± 0,10	0,44	0,87

лучше, чем датчик, основанный на целевом отклике датчика CO. Это, вероятно, связано, опять же, с высоким коэффициентом корреляции, существующим между Концентрации CO и бензола в выбранном сценарии (r = 0,93, SCC = 0,86) и очень хорошие характеристики целевой группы NMHC. датчик. Наилучшие результаты достигаются при выборе подмножества массива датчиков с использованием откликов датчиков как CO, так и NHMC при вставке.

Таблица 9

Характеристики оценки концентрации CO схемы нейронной регрессии, рассчитанные для различных длин обучающего набора с использованием отклика твердотельного датчика CO и NMHC. как вектор признаков (фиксированная длина набора тестов, настройка перекрестной проверки). В скрытом слое использовались пять нейронов, для контроля сложности использовался ABR. Уверенность интервалы указаны для MRE, MAE и SCC. При использовании записи данных более 10 дней повышения производительности не происходит.

Часы	MRE	ки	СТД РЕ	МАЗ (мг/м3)	КИ (мг/м3)	Стандартная ПДК (мг/м3)	CCC	ки
12	0,35	±0,01	0,67	0,53	±0,02	0,48	0,84	±0,01
24	0,31	±0,01	0,62	0,48	±0,02	0,46	0,85	±0,01
48	0,31	±0,01	0,62	0,47	±0,03	0,45	0,85	±0,01
72	0,30	±0,02	0,61	0,47	±0,05	0,46	0,85	±0,05
96	0,30	±0,02	0,62	0,45	±0,04	0,44	0,86	±0,02
168	0,29	±0,03	0,64	0,44	±0,06	0,42	0,87	±0,01
240	0,30	±0,04	0,64	0,45	±0,08	0,44	0,87	±0,01
360	0,28	±0,02	0,67	0,42	±0,05	0,43	0,87	±0,02
480	0,30	±0,04	0,66	0,44	±0,10	0,42	0,87	±0,02
540	0,29	±0,03	0,70	0,42	±0,05	0,41	0,87	±0,01
600	0,29	±0,04	0,67	0,43	±0,10	0,42	0,87	±0,02
700	0,27	±0,04	0,65	0,40	±0,12	0,41	0,87	±0,02
800	0,27	±0,06	0,63	0,42	±0,17	0,42	0,87	±0,03
900	0,27	±0,20	0,70	0,39	±0,21	0,41	0,87	±0,08
1200	0,30	±0,13	0,71	0,44	±0,81	0,43	0,87	±0,04




Рис. 5. Качественный ход среднедневной абсолютной ошибки (мг/м³) в задаче оценки концентрации CO. Синяя линия показывает MAE, полученную с использованием всех отклик датчиков для состава вектора признаков, в то время как красная линия изображает MAE получен с использованием только отклика датчика CO и NMHC. Несмотря на то, что общий подход в летнее время имеет небольшое преимущество, в начале зимнего периода на него приходится значительно большая ошибка, весьма вероятно, что это связано с изменениями в относительное распределение концентраций NO2, NOx и CO. (Для интерпретации ссылки на цвет в легенде к этому рисунку, читатель отсылается к веб-версии статьи.)

Реакции датчиков NO2 и NOx привели к ухудшению показателей производительности. На рис. 3 показаны различия между оценками концентрации предоставленная моделью, и истинная концентрация, о которой сообщает обычный анализатор, в то время как рис. 4 показывает результаты MAE этого набора, в то время как рис. 5 показывает результаты MAE этого набора.

Оценка производительности проводилась с использованием ABR в соответствии с к процедуре, описанной в предыдущей главе, со значительным сокращением времени, необходимого для обычных процедур. Как контрольная проверка, мы сообщаем результаты обычной нейронной сети процедура оптимизации гиперпараметров для функции CO, NMHC вектор. Контроль сложности был достигнут путем контроля цели эмпирическая ошибка должна быть выбрана в [10e-3, 2 × 10e-3, 4 × 10e-3] набор, в то время как количество нейронов варьировало в наборе [5,10,15,20]. Рано остановка не была выбрана, потому что это помешало бы получению результатов сравнение путем изменения продолжительности набора тестов. Для каждой эмпирической ошибки и количества скрытых нейронов результаты отбора должны были быть усреднены по 20 различным тренировочным прогонам. Лучшие результаты были получено для 10 нейронов и целевой эмпирической ошибки 2 × 10e-3 и были очень похожи (MRE = 0,27, MAE = 0,36) на полученные с

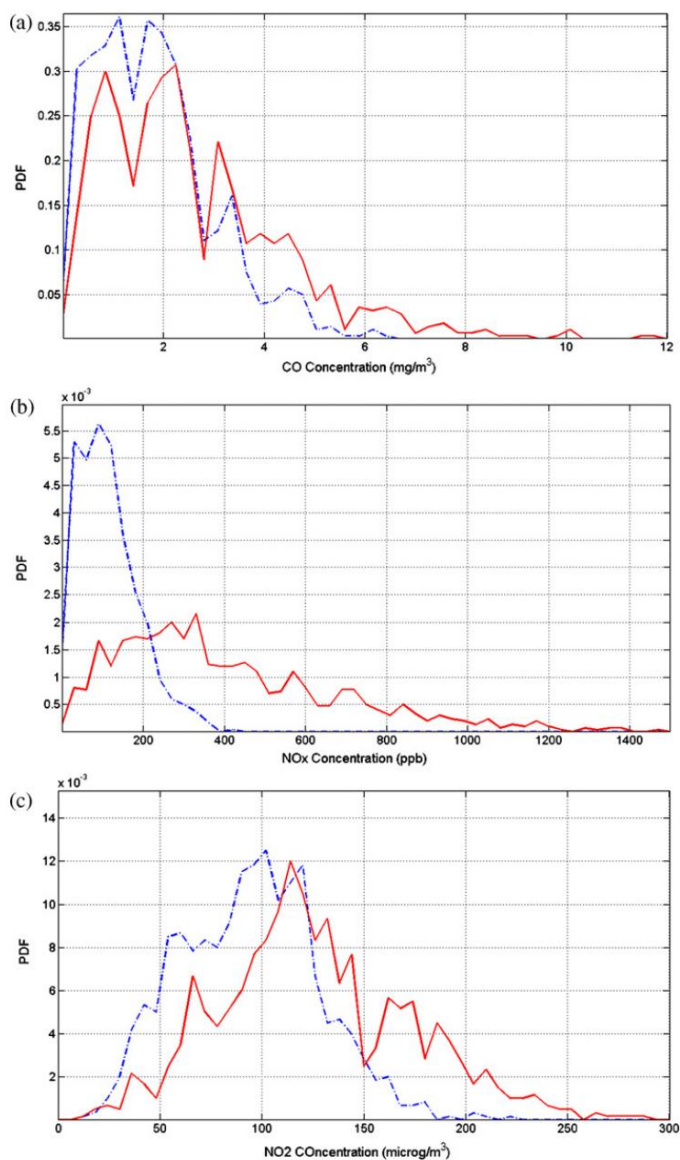


Рис. 6. Функция плотности вероятности (PDF) непараметрических оценок в летнее время (синий, штрих-пунктир) и в зимнее время (красный сплошной) для концентраций CO (a), NOx (b) и NO2 (c). Обнаружены значительные изменения в распределении NOx и NO2, приводящие к изменениям в соотношениях концентраций по отношению к CO. Эти модификации определены как основной фактор ухудшения характеристик в зимнее время, когда для оценки CO используются отклики датчиков NOx и NO2. (Для интерпретации ссылок на цвет в легенде к этому рисунку читатель отсылается к веб-версии статьи.)

ABR с использованием того же вектора признаков. Та же процедура была применена ко всему массиву и снова привела к тем же значениям ($MRE = 0,32$, $MAE = 0,47$), что и полученные с помощью ABR.

Подводя итог, можно сказать, что основное различие в отношении оценки концентрации бензола связано, прежде всего, с худшими характеристиками датчика CO, NOx и NO2 при оценке целевого газа. Однако наличие других датчиков в значительной степени способствует смягчению этой проблемы в результате эффектов корреляции.

Эти результаты предостерегают от неизбирательного использования всех линий датчиков при обучении подсистемы объединения датчиков в этом сценарии. Таким образом, они также настоятельно рекомендуют использовать различные подсистемы слияния датчиков, каждая из которых обучена прогнозированию одного загрязняющего вещества. В этом случае алгоритмы выбора признаков могут помочь выбрать оптимальный состав массива, который будет использоваться для каждой задачи прогнозирования концентрации загрязняющих веществ. В таблицах 8 и 9 мы приводим результаты оценки производительности по сравнению с продолжительностью тренировочного набора для CO по

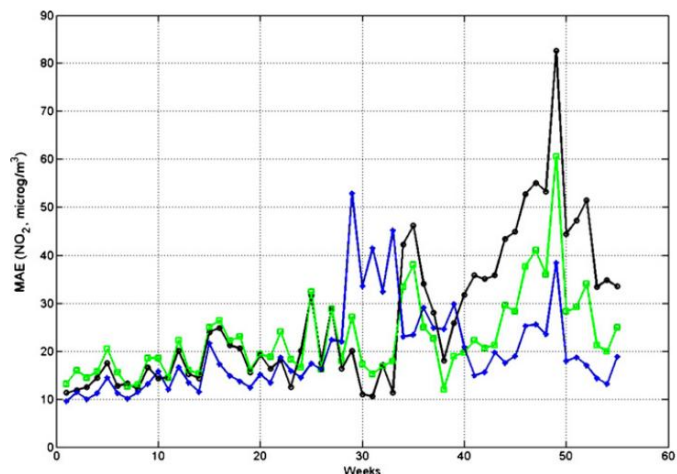


Рис. 7. Среднедневная абсолютная ошибка в задаче определения концентрации NO2. Синяя линия (точки) показывает МАЭ, полученную с использованием отклика всех датчиков для состава вектора признаков, а зеленая линия (квадраты) изображает МАЭ, полученную с использованием отклика датчиков NO2, NOx, O3, T и RH. Черная линия (круг) показывает оценку на основе датчиков NO2, T и относительной влажности. Подход с использованием всех датчиков сохраняет значительное преимущество в течение большей части периода испытаний и обеспечивает наилучшие общие показатели производительности. (Для интерпретации ссылок на цвет в легенде к этому рисунку читатель отсылается к веб-версии статьи.)

используя наилучшую композицию вектора признаков, используя, соответственно, одиночный набор тестов и подход с перекрестной проверкой, описанные в разделе 4.1.

Результаты подтверждают оптимальность выбора двухнедельной продолжительности с учетом состава вектора признаков, в то время как, конечно, производительность в целом выше.

4.3. Оценка производительности с течением времени

Наконец, начиная с 10-дневного тренировочного набора, мы исследовали индекс производительности MAE для CO по неделям в течение 55 недель, чтобы проверить их изменение с течением времени. Кроме того, используя несколько векторных композиций признаков, мы исследовали влияние использования различных откликов сенсоров на оценку концентрации во времени.

Как мы обнаружили для бензола, краткосрочные индексы производительности, рассчитанные для этого вида, показали, что они ухудшаются со временем, в частности, значительные скачки производительности обнаруживаются через 6 месяцев после окончания калибровочного набора (см. рис. 5). Экспериментально мы обнаружили, что при использовании всех доступных ответов датчика использование только ответа датчика CO вызывает небольшое снижение производительности в летнее время и значительное повышение производительности в зимнее время. В частности, мы полагаем, что это объясняется определенными изменениями в распределении концентраций NOx, а также NO2 в зимнее время. Эти изменения нарушают отношения, изученные системой регрессии при просмотре тренировочного набора Spring time. Вместо этого комбинированное использование откликов датчиков CO и NMHC дает положительный эффект во время всего набора испытаний. Подводя итог, можно сказать, что описательная способность датчиков NOx и NO2 и корреляция их целевых газов с CO имеют меньший вес в общей экономии производительности по сравнению с вводящими в заблуждение эффектами, вызванными изменениями распределения их целей в зимнее время (см. рис. 6a) – в). Что касается понедельной ошибки оценки NO2 (см. рис. 7 и 8), мы видим, как упоминалось выше, что подход, основанный на использовании всех датчиков, способен обеспечить наилучшую производительность за счет использования положительных эффектов корреляции, однако даже здесь производительность ухудшается. в зимнее время это очевидно.

Совокупность результатов, представленных в [8] и в настоящей статье, позволяет нам считать возможным использование полевых данных для получения подходящей калибровки мультисенсорных устройств в рамках мониторинга загрязнения воздуха в городе. Однако эти калибровки страдают




Рис. 8. Среднедневная относительная ошибка в задаче определения концентрации NO₂.

Синяя линия (точки) показывает МАЭ, полученную с использованием отклика всех датчиков для состава вектора признаков, а зеленая линия (квадраты) изображает МАЭ, полученную с использованием отклика датчиков NO₂, NO_x, O₃, T и RH. Черная линия (круг) показывает оценку на основе датчиков NO₂, T и относительной влажности. (Для интерпретации ссылок на цвет в легенде к этому рисунку читатель отсылается к веб-версии статьи.)

долгосрочное снижение производительности и чувствительны к изменениям распределения относительной концентрации, возникающим на сезонной основе или в результате определенных событий. Это гораздо более очевидно, когда из-за плохих характеристик конкретных датчиков лучший статистический регрессор должен полагаться на коэффициенты корреляции конкретных видов для конкретного сценария. Остается еще доказать, можно ли использовать калибровку для конкретных участков для оценки концентрации на участках с небольшим расстоянием. В этом случае мы полагаем, что производительность будет в конечном итоге связана с зависимостью от сайта моделей корреляции видов, которые необходимо

5. Выводы и дальнейшие работы

В этой работе мы дополнительно исследовали осуществимость подхода калибровки на месте для мультисенсорного устройства в сценарии мониторинга загрязнения воздуха. Результаты, полученные для типичных загрязнителей городского воздуха, т.е. CO, NO₂, NO_x и бензола, были опубликованы и обсуждены. Общие результаты подтверждают, что относительно короткая продолжительность тренировочного набора, около двух недель, может справиться с циклическим поведением распределения концентраций, что приводит к оптимальным характеристикам, и быть достаточно нечувствительным к выбросам. Это очень обнадеживает возможность использования мультисенсорных устройств вместе с мобильными обычными анализаторами для калибровки на месте, для уплотнения разреженной сети мониторинга загрязнения, особенно в исторических центрах городов.

Результаты выбора признаков определенно предполагают использование нескольких регрессоров, каждый из которых специально разработан и обучен для оценки концентрации определенного вида. Таким образом, разработчик может свободно выбирать лучший набор функций для конкретной задачи регрессии, получая оптимальные результаты.

Кроме того, анализ выбора признаков подтвердил влияние корреляций концентрации видов, связанных со сценарием, и характеристик конкретных датчиков на общие оценки.

Когда определенные датчики не могут правильно отследить их целевую концентрацию частиц, существование сильной корреляции между этой концентрацией частиц и другой, чей целевой датчик показывает хорошую производительность, может помочь массиву восстановиться, что в конечном итоге приведет к значительному повышению уровня производительности. Однако в этом случае изменения в относительном статистическом распределении видов, например, связанные с эффектом обогрева дома в зимнее время, могут оказывать негативное влияние на долгосрочные характеристики нейронной калибровки. Такое же отрицательное влияние, вероятно, можно было бы наблюдать при использовании калибровки, полученной для конкретного сайта, показывающей специфичную для сайта мул.

варьировать распределение концентрации и управлять мультисенсорным устройством на значительном удалении.

Благодарности

Эта работа была частично профинансирована Pirelli Labs. Авторы благодарят проф. Чиро Д'Элия из Университета Кассино за полезные обсуждения автокоррелированных временных рядов и циклостационарных процессов.

Рекомендации

- [1] Н. А. Маццео, Л. Е. Венегас, Оценка турбулентности от движения с использованием экспериментальных данных, полученных в уличном каньоне, Междунар. Дж. Окружающая среда. Загрязн. 25 (2005) 164–176.
- [2] С. Вардулакис, Б. Э. Фишер, К. Периклеус, Н. Гонсалес-Флеска, Моделирование качества воздуха в уличных каньонах: обзор, Атмос. Окружающая среда. 37 (2003) 155–182.
- [3] К.А. Куртидис, И. Зиомас, К. Зерефос, Э. Космидис, П. Симеонидис, Э. Христофилопулос, С. Каратанассис, А. Мплутсос, Измерения бензола, толуола, озона, NO₂ и SO₂ в городском уличном каньоне в Салониках, Греция, Атмос. Окружающая среда. 36 (2002) 5355–5364.
- [4] Б. Крокфорд, А. Пенн, Б. Хиллер, Пространственное распределение городского загрязнения: цивилизация городского движения, в: 5-й симпозиум по дорожному и городскому загрязнению, Копенгаген, 1995.
- [5] Г. Мартинелли, М. С. Каротта, Г. Гиотти, Э. Траверса, Толстоленочные газовые сенсоры на основе наноразмерных порошков полупроводниковых оксидов, MRS Bull. 24 (1999) 30–36.
- [6] М. Каминка, П. Брейл, К. Пийолат, Калибровка многомерного газоанализатора для измерения загрязнения атмосферы, Sens. Actuators B Chem. 18 (2006) 323–327.
- [7] MC Carotta, G. Martinelli, L. Crema, C. Malagu, M. Merli, G. Ghiotti, E. Traversa, Наноструктурные толстоленочные датчики газа для мониторинга загрязнителей атмосферы: количественный анализ полевых испытаний, Sens. Actuators B хим. 76 (2001) 336–342.
- [8] С. Де Вито, Э. Масера, М. Пига, Л. Мартинотто, Г. Ди Франсия, О полевой калибровке электронного носа для оценки бензола в сценарии мониторинга городского загрязнения, Sens. Actuators B Chem. 129 (2008) 750–757.
- [9] W. Tsujita, A. Yoshino, H. Ishida, T. Morizumi, Сеть газовых датчиков для мониторинга загрязнения воздуха, Sens. Actuators B Chem. 110 (2005) 304–311.
- [10] CM Bishop, Распознавание образов и машинное обучение, Springer Science, 2006, ISBN 0-387-31073-8.
- [11] М. Дж. С. Бервальери, Замечания по использованию многослойных перцептронов для анализа данных матрицы химических датчиков, IEEE Sens. J. 4 (2004) 355–363.
- [12] <http://www.pirellilabs.com>.
- [13] М.Т. Хаган, М.Б. Менхай, Обучение сетей с прямой связью с помощью алгоритма Марквардта, IEEE Trans. Нейронные сети 5 (1994) 989–993.
- [14] FD Foresee, MT Hagan, Приближение Гаусса-Ньютона к байесовской регуляризации, в: Proceedings of the 1997 International Joint Conference on Neural Networks, 1997, pp. 1930–1935.
- [15] DJC MacKay, байесовская интерполяция, нейронные вычисления. 4 (3) (1992) 415–447.
- [16] Н.Ф. Чжан, Расчет неопределенности среднего автокоррелированного измерения. измерений, Метрология 43 (2006) 276–281.

Биографии

Саверио Де Вито получил степень магистра информатики в Университете Неаполя «Федерико II» в 1998 году. В 1998 и 1999 годах он был научным сотрудником в лаборатории искусственного зрения и интеллектуальных систем вышеупомянутого университета, работая над компьютерной диагностикой рака молочной железы. С 1999 по 2004 год он работал в ITC engineering в качестве технического менеджера по исследованиям и разработкам в рамках проектов спутниковой телемедицины, наблюдения Земли и дистанционного обучения. В июне 2004 года он присоединился к ENEA в качестве исследователя. Его исследовательские интересы включают статистическое распознавание образов, электронные носы, беспроводные сенсорные сети и компьютерную диагностику. С 2005 года он является профессором по контракту прикладной информатики в Университете Кассино.

Марко Пига получил степень магистра физики в Университете Феррары (Италия) в 1999 году. С 2004 года научный сотрудник отдела исследований и разработок Pirelli в Милане. В настоящее время он участвует в проекте распределенной сенсорной сети, особенно в области мониторинга загрязнителей окружающей среды.

Лука Мартинотто получил степень магистра в области промышленной химии в Миланском университете (Италия) в 1995 году. С 1996 года он работал научным сотрудником в исследовательском центре Pirelli в Милане. Он отвечает за исследовательскую деятельность Pirelli в области DSN.

Джироламо Ди Франча получил степень по физике в Неаполитанском университете имени Федерико II. В 1985 году он начал свою исследовательскую деятельность в области изготовления и определения характеристик полупроводниковых солнечных элементов (c-Si, GaAs), ранее работавших в Ansaldo comp. в Генуе, а затем в исследовательском центре ENEA в Риме, где он был назначен штатным исследователем в 1988 году. С 1991 года он присоединился к исследовательскому центру ENEA в Неаполе, где, начиная с 1992 года, он исследовал устройства на основе пористого кремния. В 1996 году он основал там Лабораторию газовых датчиков, в основном занимающуюся изготовлением и определением характеристик устройств на основе наноматериалов и полимерных нанокомпозитов.